

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
Université des Sciences et de la Technologie Houari Boumediene
Faculté d'électronique et d'informatique
Département d'informatique



Mémoire de Master

Domaine : Informatique

Spécialité : Systèmes Informatiques Intelligents

Thème

MINIMISATION DE LA CONSOMATION D'ENERGIE DANS UN
RESEAUX DE CAPTEURS (WSN) PAR UNE APPROCHE
COOPERATIVE DE METHAHEURISTIQUES

Présenté par :

- EL DJAZAERY IBRAHIM
- CHEKLAT KHADIDJA

Proposé et dirigé par :

- Pr. BOUKRA ABDELMADJID
- Mme. OUAFI MOUNIRA

Projet N° : 085/2019

Remerciment

Nous tenons à remercier en tout premier lieu ALLAH tout puissant de nous avoir donné la volonté et la puissance d'élaborer ce modeste travail.

Nous adressons nos vifs remerciements à nos encadreurs Pr. BOUKRA et Mme OUAFI qui nous a formulé ses précieux conseils et qui nous a facilité la tâche par ses recommandations et ses orientations.

Nos remerciements vont également à toute personne ayant apporté son aide de près ou de loin, à la réalisation de ce travail. Notamment nos amis et nos familles respectives qui nous ont fourni l'environnement adéquat pour la mise en œuvre de notre projet.

Nous remercions les membres du jury pour avoir accepté d'examiner et de juger ce modeste travail.

Enfin nous souhaitons adresser nos remerciements au corps enseignant du département informatique, Faculté d'Electronique et d'Informatique –USTHB–, pour l'enseignement de qualité et qui par leurs conseils et leurs critiques ont guidé nos réflexions.

Dédicace

Table des figures		4
Liste des algorithmes		6
Introduction général		8
1 Notions sur les réseaux de capteurs sans fils		10
1.1 Introduction		10
1.2 Un réseau de capteur sans-fil		10
1.3 Architecture d'un capteur sans-fil		11
1.4 Architecture d'un réseau de capteurs sans-fil		13
1.4.1 Les couches WSN OSI		13
1.4.2 Les plans de gestion de la pile protocolaire :		14
1.5 Domaines d'application des réseaux de capteurs		15
1.5.1 Domaine militaire		15
1.5.2 Domaine médicale		15
1.5.3 Domaine environnementale		16
1.5.4 Domaine commercial		16
1.6 Le problème majeur d'un réseau de capteurs sans fil et le chal- lenge :		17

1.7	Conclusion :	18
2	Optimisation combinatoire et méthodes de résolutions	19
2.1	Introduction	19
2.2	Techniques d'optimisation combinatoire :	19
2.2.1	Méthodes exacte	21
2.2.2	Les méthodes approchées :	22
2.3	Conclusion	37
3	Le problème de l'arbre dominant (DTP)	38
3.1	Introduction	38
3.2	Définition du problème	38
3.3	Complexité et approximation	39
3.4	Notions de base	41
3.4.1	Arbre couvrant de poids minimal (MST) :	41
3.4.2	L'élitage (Pruning) :	43
3.5	Les travaux relatifs	43
3.5.1	L'heuristique pour le problème de l'arbre dominant (H_DT)	44
3.5.2	Colonie d'abeilles artificielle pour le DTP (ABC_DT) .	46
3.6	Algorithme génétique stationnaire	48
3.7	L'algorithme évolutionnaire avec mutation guidée EA/G	50
3.8	Conclusion	57
4	Approche proposée	58
4.1	Introduction	58
4.2	Représentation du graphe modélisant le problème	58
4.3	présentation d'une solution	58
4.4	Méthode d'extraction d'un arbre dominant à partir du vecteur solution	58

4.5	La méthode de connection	59
4.6	Approche proposée	59
4.6.1	description des méta-heuristiques utilisées	60
4.6.2	Description de l'approche coopérative	67
4.7	Conclusion	69
5	Étude expérimentale	70
5.1	Introduction	70
5.2	Environnement de travail	70
5.2.1	Environnement matériel	70
5.2.2	Environnement logiciel	70
5.3	Jeux de données utilisées	71
5.4	Expérimentation	71
5.4.1	Étude comparative	72
5.4.2	Analyse graphique	79
5.5	Conclusion	81
	Conclusion général	82

Notions sur les réseaux de capteurs sans fils

1.1	Capteur sans fils	10
1.2	Architecture d'un réseau de capteurs sans fil	11
1.3	Architecture d'un nœud capteur	11
1.4	Consommation d'énergie dans un nœud capteur. [1, 2]	12
1.5	L'architecture d'un WSN	13
1.6	Les cas d'utilisation d'un réseau de capteurs sans-fil	17

Optimisation combinatoire et méthodes de résolutions

2.1	Différence entre un optimum global et des optima locaux	20
2.2	Classification des méthodes de résolution d'optimisation combinatoire	21
2.3	Organigramme illustrant le fonctionnement de la recherche Recuit simulé	24
2.4	Organigramme illustrant le Fonctionnement de l'algorithme TS .	26
2.5	Principe d'un algorithme évolutionnaire (EA) [3].	29
2.6	Organigramme d'un algorithme génétique	30
2.7	processus de migration de BBO	35
2.8	Schéma explicatif d'un algorithme mémétique	37

Le problème de l'arbre dominant (DTP)

3.1	Exemple de réduction du graphe G en G'	40
3.2	Exemple de réduction du graphe G en G'	42
3.3	illustration de l'algorithme de Prim	43

Approche proposée

4.1	Exemple de croisement uniforme	63
4.2	Représentation schématique de la mutation	64
4.3	Coopération des méta-heuristiques	68

Étude expérimentale

5.1	Caractéristiques de la machine utilisée	70
5.2	Diagrammes d'exécutions de la méthode ACO et la méthode coopérative	74
5.3	Diagrammes d'exécutions de la méthode BBO et la méthode coopérative	75
5.4	Diagrammes d'exécutions de la méthode GA et la méthode coopérative	76
5.5	Diagrammes d'exécutions des approches proposées	80
5.6	Diagrammes de la Qualité moyenne de la solution AVG de des approches proposées	81

LISTE DES ALGORITHMES

1	Recuit simulé	25
2	Recherche Taboue	27
3	Recherche Local	28
4	Recherche à voisinages variables (VNS)	28
5	Algorithme génétique	30
6	L'optimisation des colonies de fourmis (ACO)	32
7	L'algorithme à base de biogéographie (BBO)	34
8	migration	34
9	Simple Algorithme mémétique	36
10	Recuit simulé	41
11	Prim	42
12	pseudo-code H_DT	45
13	Pseudo-code de ABC	47
14	Pseudo-code de détermination d'une solution voisine	48
15	Pseudo-code de l'algorithme SSGA	50
16	Pseudo-code de la procédure pruning	52
17	Pseudo-code de la solution initiale de EA/G-MP	53
18	Pseudo-code de l'initialisation du vecteur de probabilités de EA/G-MP.	53

19	Pseudo-code de la mise à jour du vecteur de probabilités de EA/G-MP.	54
20	Pseudo-code de GM	55
21	Pseudo-code de l'opérateur de réparation	56
22	EA/G-MP pour DTP	57
23	ACO DT	62
24	Génétique DT	64
25	Migration BBO DT	65
26	Mutation BBO DT	65
27	Algorithme BBO DT	67
28	Algorithme de la méta-heuristique maître	68
29	Algorithme de coopération	69

Introduction général

Les réseaux de capteurs sans fil sont récemment devenus un sujet de recherche de premier plan. L'évolution technologique de ces derniers a permis une production de masse peu coûteuse de nœuds de capteurs autonomes, qui, malgré leurs miniaturisation, ont des capacités de détection, de traitement et de communication particulièrement avancées [4], et ont un fort potentiel économique à long terme. Flexibilité, hautes capacités de captage, coût réduit, installation rapide sont les caractéristiques qui ont permis aux réseaux de capteurs d'avoir des nouveaux domaines d'applications multiples et excitants. Ce large étendu d'application fera de cette technologie émergente une partie intégrale de nos vies futures.

Cependant, la réalisation des réseaux de capteurs nécessite la satisfaction de certaines contraintes qui découlent d'un nombre de facteurs guidant la phase de conception, tel que la tolérance aux pannes, la scalabilité, le coût et la consommation de l'énergie qui est la substance de notre sujet.

Le problème majeur des réseaux de capteurs sans fil est le problème des trous d'énergie. Les nœuds les plus proches de la région de puits mourront plus tôt des sous-régions externes car ils envoient leurs propres données et transmettent également les données des sous-régions externes au récepteur. Donc, après très peu de temps, un trou d'énergie vient près de la région de l'évier.

« PARAGRAPHE pas clair. à voir »

Après cela, les données ne peuvent plus être transmises, même s'il reste encore de l'énergie dans les nœuds de la région externe, ce qui affecte la durée de vie du réseau. Par conséquent, pour permettre d'augmenter la longévité, d'un nœud capteur nous nous intéressons particulièrement à la résolution d'un problème d'optimisation combinatoire, qui est relativement nouveau dans les RCSFs, intitulé le problème de l'arbre dominant ou DTP. Ce dernier offre une ossature pour le routage des données à travers le réseau. Les informations de routage seront stockées uniquement au niveau des nœuds de l'arbre dominant.

Du fait que ce problème soit NP-Difficile [5, 6], nous avons fait recours aux méthodes d'optimisation combinatoire approchées, à savoir, les méta-heuristiques, tout en tirant profit des propriétés de la théorie des graphes. Ensuite, des essais d'amélioration sont apportés en travaillant sur certains paramètres afin d'obtenir les méthodes les plus efficaces possibles. La qualité de chaque méthode est évaluée en la comparant à d'autres méthodes proposées pour le problème étu-

dié. Malheureusement, d'après les "No Free Lunch Theorems" [7], il n'existe pas de métaheuristique qui soit meilleure que toutes les autres métaheuristiques pour tous les problèmes. Dans la pratique, il existera toujours des instances pour lesquelles une métaheuristique est meilleure qu'une autre. Quelque soit la métaheuristique choisie, elle présente des avantages et des inconvénients. C'est la raison pour laquelle la méthode de coopération a été proposée. Cette méthode propose de regrouper un ensemble d'heuristiques ou métaheuristiques et d'établir un mécanisme pour identifier et sélectionner les méthodes de recherche les plus efficaces au cours du processus d'optimisation. Généralement, certaines études visent à produire des heuristiques constructives qui construiront une solution, étape par étape. Les heuristiques sont utilisées pour décider comment étendre une solution partielle. Ces méthodes ont tendance à être rapide. D'autres études visent à produire des heuristiques d'amélioration ou de perturbation travaillant sur une solution candidate déterminée et essayant d'améliorer sa qualité. Ces méthodes sont plus lentes mais fournissent les meilleurs résultats finaux.

Notre mémoire s'articule autour de cinq chapitres. Le premier présente un état de l'art des Réseaux de Capteurs Sans Fils (RCSF). L'étude des méthodes d'optimisation combinatoires et de résolution exactes et approchées fait l'objet du chapitre deux. Le troisième chapitre sera consacré à l'étude du problème de l'arbre dominant ainsi que des différents travaux effectués pour sa résolution et sur lesquels repose notre travail. Dans le quatrième chapitre, nous présentons l'approche de résolution développée. Quant au chapitre cinq, il est consacré à l'expérimentation ainsi qu'à l'analyse des performances. Nous terminons par une conclusion générale et des perspectives.

CHAPITRE 1

NOTIONS SUR LES RÉSEAUX DE CAPTEURS SANS FILS

1.1 Introduction

L'une des récentes avancées dans la micro électronique et des technologies sans-fil qui confortent la présence de l'informatique et de l'électronique au cœur du monde réel ont permis de développer des capteurs de petite taille. Ces micro-capteurs sont dotés d'une capacités de traitement permettant de collecter et de transmettre des données environnementales d'une manière autonome. Les réseaux de capteurs sans fil ou WSNs (Wireless Sensor Networks) sont constitués d'un ensemble de capteurs sans fil s'auto organisant pour acquérir des données de leur environnement immédiat, de les traiter et de les communiquer. Dans ce premier chapitre, nous présenterons un ensemble de généralités sur les réseaux de capteurs, notamment sur leur architecture et leurs domaines d'applications.

1.2 Un réseau de capteur sans-fil

Un réseau de capteur sans fil est un type spécial de réseau ad-hoc où la plupart de ces nœuds sont des micro-capteurs dispersés dans une zone géographique appelée zone de captage. La position de ces nœuds n'est pas obligatoirement déterminée, ils utilisent une communication sans fil pour acheminer les données captées avec un routage multi sauts vers un nœud collecteur appelé nœud puits (Sink). Ces capteurs comme ils ont été décrit au paravent sont des diapositifs de taille extrêmement réduite avec des sources limitées, autonome, capable de traiter et transmettre les informations.




Fig. 1.1 – Capteur sans fils

Les réseaux de capteurs utilisent un très grand nombre de ces capteurs, pour former un réseau sans infrastructure établie. Chaque capteur relayant l'information sur sa propre zone de couverture, le réseau se trouve entièrement couvert.

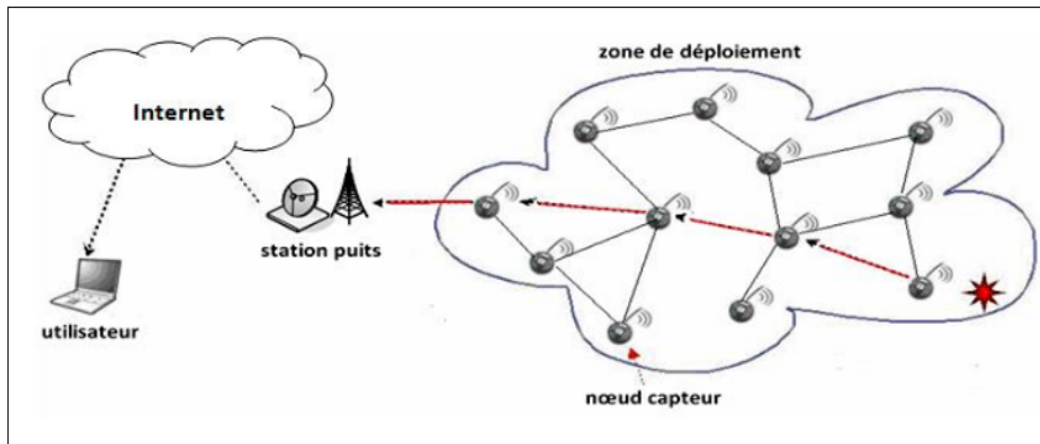


Fig. 1.2 – Architecture d'un réseau de capteurs sans fil

1.3 Architecture d'un capteur sans-fil

Un capteur est composé de quatre composants de base : Unité d'acquisition peut être nommé aussi unité de capture, unité de traitement, unité de communication (unité d'émission/réception), et une unité d'énergie. Il se peut aussi qu'il existe d'autres composants additionnels dépendant de l'application, par exemples : un générateur d'énergie, un système de localisation, et un mobilisateur [8].

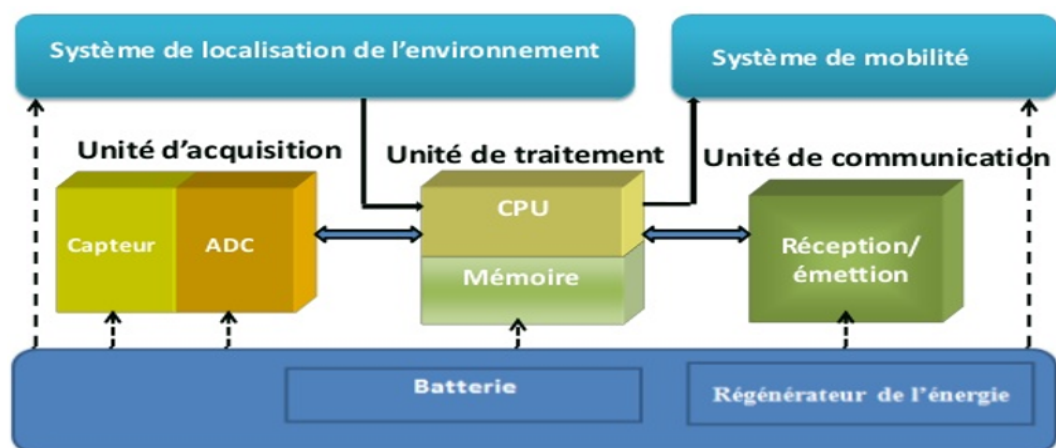


Fig. 1.3 – Architecture d'un nœud capteur

- **Unité d'acquisition** : Se compose généralement de deux sous unités : un capteur et un convertisseur (ADC) (analogique, numérique). Les signaux

analogiques mesurés par le capteur sont convertis en signaux numériques (digitaux) et sont transmis à l'unité de traitement [8].

- **Unité de traitement** : L'unité de traitement, comprend un processeur associé généralement à une petite unité de stockage et fonctionne à l'aide d'un système d'exploitation spécialement conçu pour les micro-capteurs (TinyOS [9], par exemple). Cette unité est chargée d'exécuter les protocoles de communication qui permettent la collaboration entre les capteurs du réseau. Elle peut aussi analyser les données captées pour alléger la tâche des stations puits. De plus, l'unité de traitement nécessite un stockage pour minimiser la taille des messages transmis et cela en appliquant un traitement local et une agrégation de données [10].
- **Unité de communication** : Cette unité est responsable de l'émission et de la réception au moyen de support sans fil. Il existe trois schéma de communication pour les réseaux de capteurs : La communication optique (laser), L'infrarouge et la communication par fréquence radio. D'après les recherches scientifique la communication optique consomme moins d'énergie que la communication qui utilise la fréquence radio, son inconvénient est l'utilisation d'une ligne optique qui est sensible à la perturbation physique. L'infrarouge a une capacité de diffusion très limitée et il n'a pas besoin de l'antenne contrairement au fréquence radio qui utilise des antennes mais très simple à l'utiliser.
- **Unité de contrôle d'énergie(batterie)** : C'est l'unité la plus importante. Son rôle est de distribuer de manière équitable l'énergie disponible entre les différentes unités et de réduire les dépenses en mettant en veille les composants inactifs




Fig. 1.4 – Consommation d'énergie dans un nœud capteur. [1, 2]

1.4 Architecture d'un réseau de capteurs sans-fil

La plupart des architectures communes à un WSN suivent le modèle OSI. En principe, dans le réseau de capteurs, nous avons besoin de cinq couches : couche application, couche de transport, couche réseau, couche liaison de données et couche physique. Les cinq couches sont complétées par les plans des trois couches, comme illustré à la Figure. 1.5 .

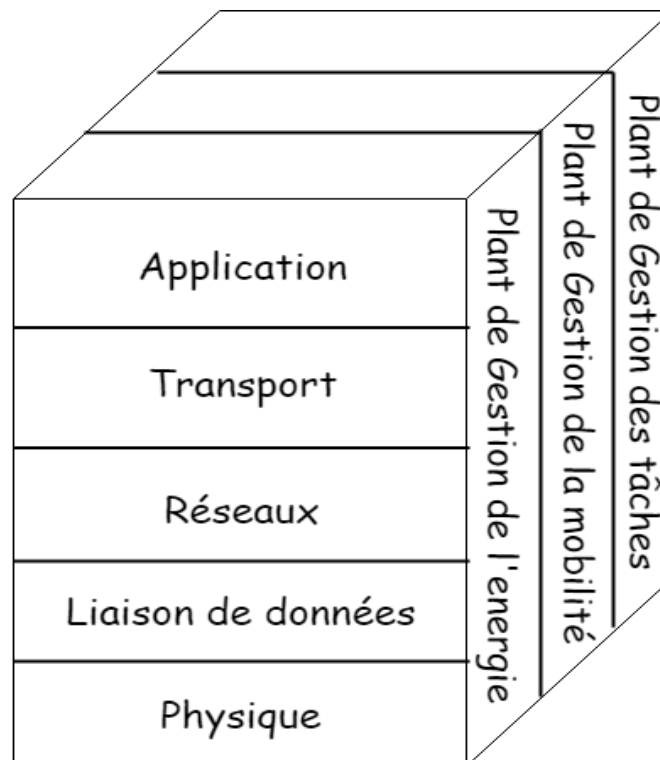


Fig. 1.5 – L'architecture d'un WSN

1.4.1 Les couches WSN OSI

- **La couche physique :** La fonction de cette couche est d'assurer la fiabilité et d'éviter la congestion, où beaucoup de protocoles conçus pour assurer cette fonction sont soit appliquée en amont ou en aval. Ces protocoles utilisent des mécanismes différents pour la détection des pertes et la récupération des pertes [11, 12]. Cette couche est particulièrement nécessaire lorsqu'un système est organisé pour accéder à d'autres réseaux.
- **La couche liaison de données :** Cette couche a pour rôle le multiplexage des flux de données, le partage de l'accès au medium et le contrôle d'erreur.

Elle assure une connexion point à point ou point à multipoint fiable dans une communication réseau. [13, 14] Elle est composée de deux couches : la couche LLC (Contrôle des Liens Logiques) et la couche MAC (Contrôle d'accès au médium). Les protocoles de la sous couche MAC sont appelés à effectuer d'importantes opérations citant :

- Etablir des liens de communication entre les nœuds capteurs voisins.
 - Fournir une fiabilité entre ces nœuds voisins.
 - Partager équitablement les canaux de communication entre les nœuds du réseau.
- **La couche réseau** : La fonction principale de cette couche est le routage. Cette couche présente de nombreux défis en fonction de l'application, mais apparemment, les principaux problèmes sont les suivants : économie d'énergie, mémoire et tampons limités, le capteur n'a pas d'ID global et doit être auto-organisé. C'est différent des réseaux informatiques avec adresse IP et dispositif central de commande [15, 16].
 - **La couche transport** : Cette couche est responsable du maintien des flux de données dans les applications utilisées et de la sauvegarde des données dans le cache des capteurs. Elle est particulièrement nécessaire pour accéder au réseau de capteurs par le biais d'un réseau externe comme l'internet [17]. A l'instar des autres couches, de nouvelles approches doivent être mises en place pour faire face aux contraintes inhérentes à ce type de réseau.
 - **La couche application** : Cette couche est responsable de la gestion des trafic. Elle permet d'envoyer des requête pour récupérer certaines informations ainsi de fournir des logiciels pour toutes les applications qui traduisent les données sous une forme compréhensible.

1.4.2 Les plans de gestion de la pile protocolaire :

En plus des cinq couches, la pile protocolaire dans un réseau de capteurs comporte trois plans de gestion de l'énergie ou couches transversaux qui sont : plan de gestion de l'énergie, plan de gestion de la mobilité et plan de gestion des tâches. Ces couches servent à gérer le réseau et à faire en sorte que les capteurs fonctionnent ensemble afin d'accroître l'efficacité globale du réseau[15].

- **Le plan de gestion d'énergie** : Ce plan gère la consommation d'énergie par les capteurs.
- **Le plan de gestion de la mobilité** : Ce niveau enregistre le mouvement des nœuds capteurs et détecte leurs position, permet de maintenir l'itinéraire d'un capteur vers un utilisateur et garde la trace de l'emplacement de ses voisins.
- **Le plan de gestion des taches** : S'occupe de la répartition des taches pour une région donnée.

1.5 Domaines d'application des réseaux de capteurs

Les WSNs trouvent leurs intérêts dans des applications diverses et innovatrices. Le champs d'application des réseaux de capteurs est devenu très large grâce à la diminution des coûts de fabrication des micro-capteurs, leurs taille réduite, l'absence des cables entre les nœuds, l'élargissement de la gamme des types de capteurs disponibles (thermique, optique, vibrations, etc.) et l'évolution des support de communication sans fil.

1.5.1 Domaine militaire

Comme dans le cas de plusieurs technologies, le domaine militaire a été un moteur d'origine pour le développement des réseaux de capteurs. Le déploiement rapide, le coût réduit, l'auto- organisation et la tolérance aux pannes des réseaux de capteurs sont des caractéristiques qui rendent ce type de réseaux un outil appréciable dans un tel domaine. [8] Un réseau de capteurs déployé sur un secteur stratégique ou complexe d'accès, permet par exemple la surveillance du champ de bataille, détection des attaques Nucléaires, Biologiques et chimiques, estimation des dommages ainsi que la reconnaissance des forces opposées et du terrain.

1.5.2 Domaine médicale

Les réseaux de capteurs sont largement répandus dans le domaine médical, incluant des applications comme : collecter des informations de meilleure qualité facilitant ainsi le diagnostic de quelques maladies et aussi l'intervention

rapide si les mesures effectuées par les capteurs sont anormales, surveiller des fonctions vitales d'un organisme vivant pourrait à l'avenir être facilitée par des micro-capteurs avalés ou implantés sous la peau ,fournir une interface d'aide pour les handicapés, collecter des informations physiologiques humaines de meilleure qualité, surveiller en permanence les malades et les médecins à l'intérieur de l'hôpital.

1.5.3 Domaine environnementale

Dans ce domaine, les capteurs peuvent êtres exploités pour suivre du déplacement des oiseaux, de petits animaux et d'insecte,détecter les catastrophes naturelles (feux de forêts, tremblements de terre, etc.), connaître la qualité de l'air et détecter la pollution, détecter des fuites des produits toxiques (gaz, produits chimiques, pétrole, etc.) dans des sites industriels tels que les centrales nucléaires et les pétrolières. Les réseaux capteurs peuvent même être utilisé dans la recherche météorologique et géophysique.

1.5.4 Domaine commercial

Les réseaux de capteurs ont prouvé leurs utilité dans le domaine commercial. Dans ce domaine on peut énumérer plusieurs applications citant : contrôler le stockage des produit ainsi que leurs livraison (concernant la chaîne du froid), suivre le procédé de production d'un produit (tous les étapes), contrôler et automatiser le processus d'usinage, ect. Pour amélioré la qualité de service d'une entreprise en terme de livraison on peut même offrir à un client la possibilité de suivre le paquet qu'il attend en temps réel et connaître la position de ce dernier.

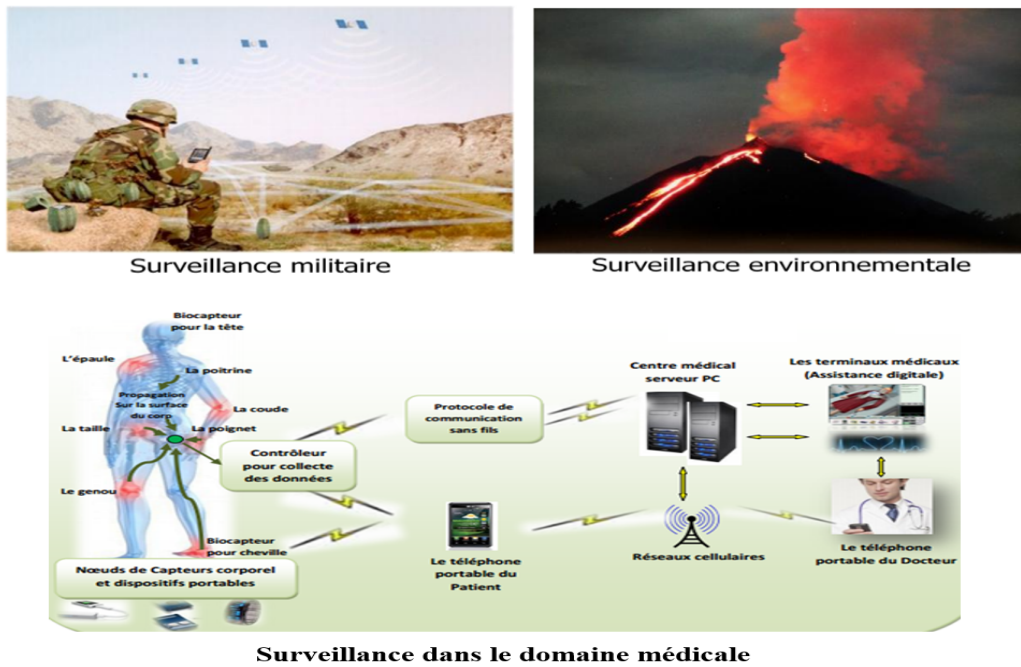


Fig. 1.6 – Les cas d'utilisation d'un réseau de capteurs sans-fil

1.6 Le problème majeur d'un réseau de capteurs sans fil et le challenge :

L'un des défis auxquels est confronté un réseau de capteurs sans fil (WSN) est la dissipation d'énergie des nœuds ayant une incidence sur la durée de vie de la batterie du nœud. Cela est dû au fait que les nœuds plus proches de nœud puits supportent des charges de trafic plus lourdes que tout autre nœud. Par conséquent, les nœuds autour du nœud puits épuiseraient leur énergie plus rapidement ce qui cause par la suite ce qu'on appelle un trou d'énergie. Après cela, les données ne peuvent plus être transmises, même s'il reste encore de l'énergie dans les nœuds de la région externe, ce qui affecte la durée de vie du réseau. Comme les réseaux de capteur sont utilisés pour des tâches critiques, penser à l'optimisation ou à la conservation de l'énergie pour chaque nœud capteur est une conséquence très probable. Dans la littérature, le concept d'ensemble dominant connecté [18–21] a été étudié pour la construction d'une ossature de routage avec une consommation d'énergie minimale dans les WSNs. Ces papiers considèrent le poids sur chaque nœud au lieu du poids sur chaque arête. Ceci a conduit à l'introduction du problème de l'arbre dominant DTP [5, 6] avec l'objectif de prolonger la durée de vie d'un capteur. [22] Le DTP semble résoudre le problème de la consommation de l'énergie mais ce dernier est gourmand en terme de temps d'exécution. Pour ce problème, les chercheurs ont pensé à l'ap-

proximation de ce problème en un problème polynomial et ils ont développé des algorithmes d'optimisation qui visent à construire un arbre dominant dans un temps minimal, nommé les méthodes approchées, tous ces détails seront exploités dans les prochains chapitres.

1.7 Conclusion :

Un réseau de capteurs est constitué de plusieurs nœuds capteurs capables de collecter et de traiter des informations sur l'environnement dans lequel ils sont déployés et de les transmettre vers un site donné (station). Ils se caractérisent par une grande flexibilité et tolérance aux fautes. Grâce à ces caractéristiques le champ d'application des réseaux de capteurs s'est étendu pour contenir la plupart des domaines tels que l'industrie, la recherche, l'environnement, la médecine ainsi que le domaine militaire. Cependant, L'apparition de ce type de réseaux a engendré plusieurs défis notamment pour la résolution du problème de trou d'énergie. Plusieurs solutions ont été proposées pour cela, mentionnant le calcul de l'arbre dominant, un problème Np-Hard, nécessite pour sa résolution les méta-heuristiques qui sont considérées comme les meilleures approches d'optimisation. des détails explicatifs font l'objet de notre prochain chapitre.

CHAPITRE 2

**OPTIMISATION COMBINATOIRE ET MÉTHODES DE
RÉSOLUTIONS**

2.1 Introduction

L'optimisation combinatoire occupe une place très importante dans divers domaines. En effet, elle définit un cadre formel pour de nombreux problèmes dans plusieurs secteurs tels que l'industrie, la finance ou tout simplement les problèmes de la vie quotidienne. La solution optimale à un problème d'optimisation ne peut que très rarement être déterminée en un temps polynomial. Il est donc souvent nécessaire de trouver des modes de résolution qui fournissent une solution de bonne qualité dans un laps de temps raisonnable. Il existe donc des méthodes de résolution exactes qui sont caractérisées par le fait qu'elles permettent d'obtenir une ou plusieurs solutions optimales, ainsi que des méthodes de résolution approchées qui fournissent des solutions de bonne qualité (proches de l'optimal mais sans garantie d'optimalité) et dont le temps de résolution sera plus faible [23].

Ce chapitre sera structuré comme suit : d'abord, nous allons présenter brièvement les techniques de routage dans les RCSFs, par la suite nous nous pencherons sur les techniques d'optimisation combinatoire, exactes et approchées surtout, pour la résolution des problèmes NP-Difficiles. Tout ceci sera clôturé par une conclusion.

Depuis une vingtaine d'années, les heuristiques les plus populaires, et également les plus efficaces, sont des techniques générales, appelées méta-heuristiques, qu'il s'agit de l'adapter à chaque problème dont sa complexité est NP-hard. Dans ce chapitre, nous allons définir c'est quoi une méta-heuristique, la classification des méthodes utilisées dans les méta-heuristiques.

2.2 Techniques d'optimisation combinatoire :

L'importance de l'optimisation combinatoire se justifie d'un côté par la grande difficulté des problèmes d'optimisation et d'un autre côté par la quantité innombrable d'applications pratiques pouvant être formulées sous la forme de tels problèmes. En effet, ces derniers sont souvent faciles à formaliser ou à exprimer, mais peuvent toutefois, être très difficiles à résoudre. Néanmoins, la plupart d'entre eux ne possèdent pas à ce jour de solution efficace valable pour toutes les données. [24]

Un problème d'optimisation combinatoire est exprimé sous forme d'une fonction objectif qui est à maximiser, ou à minimiser, selon le type de problème

traité. La résolution d'un tel problème revient à chercher la meilleure solution (optimum global) dans l'ensemble des solutions réalisables, sans pour autant être coincé dans des solutions intermédiaires (optimum locaux), propres à un sous-espace de recherche (voir Figure 2.1).




Fig. 2.1 – Différence entre un optimum global et des optima locaux

L'élégance des problèmes d'optimisation combinatoire réside dans la possibilité de les modéliser en problèmes de la théorie des graphes et ainsi profiter des outils de cette dernière.




Fig. 2.2 – Classification des méthodes de résolution d’optimisation combinatoire

De nombreuses méthodes de résolution ont été développées par la communauté scientifique (recherche opérationnelle, intelligence artificielle).

Ces méthodes sont divisées en deux grandes catégories : les méthodes exactes basées sur l’énumération de toutes les solutions réalisables, chose qui garantit la complétude de la résolution, et les méthodes approchées qui perdent en exactitude pour gagner en efficacité [19]. La figure 2.2 illustre un schéma résumant la classification des différentes méthodes discutées le long du chapitre.

2.2.1 Méthodes exacte

Ces méthodes sont dites complètes ou exactes car elles permettent de trouver la solution optimale pour une instance de taille finie dans un temps limité et de prouver son optimalité [25]. Ces méthodes se basent généralement sur une recherche complète de l’espace des combinaisons afin de trouver une solution

optimale.

Les algorithmes exacts les plus réussis dans la littérature :

- a) **La méthode séparation et évaluation (Branch and Bound)** : elle repose sur une méthode arborescente de recherche d'une solution optimale par séparations et évaluations. Le branch-and-bound est basé sur trois axes principaux : L'évaluation, la séparation, la stratégie de parcours.
 - **L'évaluation** : permet de réduire l'espace de recherche en éliminant quelques sous ensembles qui ne contiennent pas la solution optimale.
 - **La séparation** : a pour but de choisir un sous-problème parmi tous ceux non encore choisis. Elle associe donc à chacun une évaluation (valeur minimale) de toutes les solutions le constituant. Un sous-problème peut être supprimé dans le cas où son évaluation est supérieure à la meilleure solution connue.
 - **La stratégie de parcours** : c'est le processus qui permet de parcourir l'ensemble des sommets et de déterminer lequel sera séparé.
- b) **Les méthodes de coupes planes (Cutting-Plane)** : type de problème à résoudre. Néanmoins, ce sont des méthodes destinées à trouver des solutions entières pour des problèmes d'optimisation combinatoire qui sont représentés sous forme d'un programme linéaire [26] .
- c) **La méthode (Branch and Cut)** : face aux problèmes difficiles. De même que l'algorithme du "Branch and Bound". Pour cela la méthode "Branch and Cut" qui conjugue l'effort des deux algorithmes précédemment cités est utilisée [27, 28] .

2.2.2 Les méthodes approchées :

Ces méthodes s'appliquent sur tous les problèmes peu importe leurs complexités et vise à trouver une solution admissible en un temps raisonnable, mais ne garantissent pas l'optimalité d'une solution. En outre, elles ont démontré leurs robustesses et efficacités face à plusieurs problèmes d'optimisation combinatoires. Elles englobent deux classes : Heuristiques et Méta- heuristiques :

2.2.2.1 Heuristiques :

Les heuristiques sont des règles empiriques simples basées sur l'expérience, ne fournissant pas nécessairement une solution optimale. L'avantage d'utiliser une heuristique réside dans l'efficacité de calculer une solution approchée dans un temps raisonnable et ainsi accélérer le processus de résolution exact, qui peut s'avérer long pour des problèmes à large échelle. Généralement, une heuristique n'offre aucune garantie quant à la qualité de la solution. On peut distinguer une classe d'heuristique qui est les méthodes constructives.

Les approches constructives construisent une ou plusieurs combinaisons de façon incrémentale, c'est-à-dire, en partant d'une solution initiale vide, et à chaque itération, une variable est choisie (selon une heuristique ou aléatoirement) jusqu'à l'obtention d'une combinaison complète. c'est pour cela ces approches sont dites "basées sur les modèles" dans [29] .

Il existe différentes stratégies pour choisir les composants à ajouter à chaque itération, les plus connues étant les stratégies gloutonnes. Ces stratégies consistent à construire une solution pas à pas sans retour arrière, en prenant à chaque étape la solution qui semble la meilleure localement (selon une heuristique), en espérant obtenir une solution optimale.

2.2.2.2 Meta-Heuristiques :

Une Méta-heuristique peut être définie comme une méthode algorithmique capable de guider et d'orienter le processus de recherche dans un espace de solution (souvent très grand) à des régions riches en solutions optimales dans le but de trouver des solutions, peut-être pas toujours optimales, en tout cas très proches de l'optimum, en un temps raisonnable.

2.2.2.3 Méthodes de voisinage (A solution unique) :

Les méthodes de voisinage se basent sur la notion de voisinage. Elle a plusieurs méthodes chacune débute avec une configuration initiale, et réalise ensuite un processus itératif qui consiste à remplacer la configuration courante par l'un de ses voisins en tenant compte de la fonction de coût. Ce processus s'arrête et retourne la meilleure configuration trouvée quand la condition d'arrêt est réalisée. Cette condition d'arrêt concerne généralement une limite pour le nombre d'itérations, le temps d'exécution ou un objectif à réaliser. Présentant

quelques méthodes :

- a) **Recuit simulé** : La recherche recuit simulé a été introduite en 1983 par Kirkpatrick et al. [30]. Cette méthode originale est basée sur les travaux bien antérieurs de Metropolis et al. [31] et elle est considérée comme la plus ancienne méta-heuristique.

Le principe de fonctionnement s'inspire d'un processus d'amélioration de la qualité d'un métal solide par recherche d'un état d'énergie minimum correspondant à une structure stable de ce métal. L'état optimal correspondrait à une structure moléculaire régulière parfaite. En partant d'une température élevée où le métal serait liquide, on refroidit le métal progressivement en tentant de trouver le meilleur équilibre thermodynamique.

La popularité du recuit simulé a été incontestable pendant des années. D'abord cette méthode est facile à implémenter et elle a permis de résoudre de nombreux problèmes NP-difficiles [32, 33].

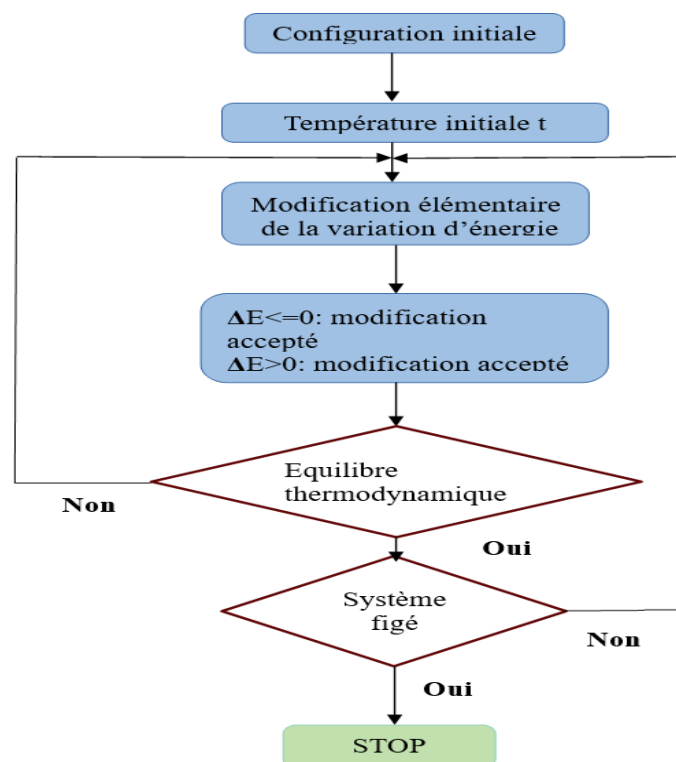


Fig. 2.3 – Organigramme illustrant le fonctionnement de la recherche Recuit simulé

Algorithme 1 : Recuit simulé

```
 $t \leftarrow 0$  , Initialiser la température  $T$  en fonction du schéma de
refroidissement
 $s \leftarrow s_0$  , une solution initiale
 $Best \leftarrow S$ 
tant que ( $Best$  est la meilleure)  $\cap$  ( $nombre\ iter=max$ )  $\cap$  ( $t \leq 0$ ) faire
     $r \leftarrow s'$  où  $s' \in N(s)$ 
     $\rho \leftarrow random(0.1)$ 
     $\Delta E = f(r) - f(s)$ 
    si  $f(r) < f(s) \cup \rho < e^{-\Delta E/t}$  alors
         $s \leftarrow r$ 
    fin
    si  $f(s) < f(Best)$  alors
         $Best \leftarrow s$ 
    fin
    Décrémenter le  $t$ 
fin
```

- b) **Recherche tabou** : La méthode de recherche avec tabous, ou simplement recherche tabou (TS :Tabu Search) a été formalisée par Fred Glover en 1986 [34] . Elle utilise explicitement l'historique de la recherche, à la fois pour échapper aux minimaux locaux et pour mettre en œuvre une stratégie d'exploration. Sa principale caractéristique est en effet basée sur l'utilisation de mécanismes inspirés de la mémoire humaine. A l'inverse du recuit simulé qui génère de manière aléatoire une seule solution voisine $s' \in N(s)$ à chaque itération, la recherche tabou examine un échantillonnage de solutions de $N(s)$ et retient la meilleure s' même si s' est plus mauvaise que s . La recherche tabou ne s'arrête donc pas au premier optimum trouvé.

La méthode TS utilise une liste tabou, qui mémorise les dernières solutions rencontrées (ou des caractéristiques de solutions) vers lesquelles il est interdit de se déplacer. Ce procédé simple de mémoire permet de choisir le meilleur voisin non tabou, même si celui-ci dégrade la fonction-objectif f . Cependant, dans certains cas, les interdictions occasionnées par la liste tabou peuvent être jugées trop radicales. En effet, on risque d'éliminer (en les rendant tabous), certains mouvements particulièrement utiles. Pour éviter cela, on incorpore dans l'algorithme un mécanisme d'aspiration qui détermine des critères selon lesquels un mouvement, bien que tabou, peut quand même être accepté, s'il permet d'obtenir une meilleure solution que toutes

celles déjà parcourues.

La taille de la liste tabou contrôle la mémoire du processus de recherche. Pour favoriser l'intensification, il suffit de diminuer la taille de la liste tabou. En revanche, augmenter la taille de la liste tabou, forcera le processus de recherche à explorer des régions plus vastes, favorisant ainsi la diversification. La taille de la liste tabou peut être modifiée au cours de la recherche [35].

Une autre amélioration intéressante de la TS est l'utilisation de structure de mémoire à moyen et à long terme afin d'approfondir les notions d'intensification et de diversification.

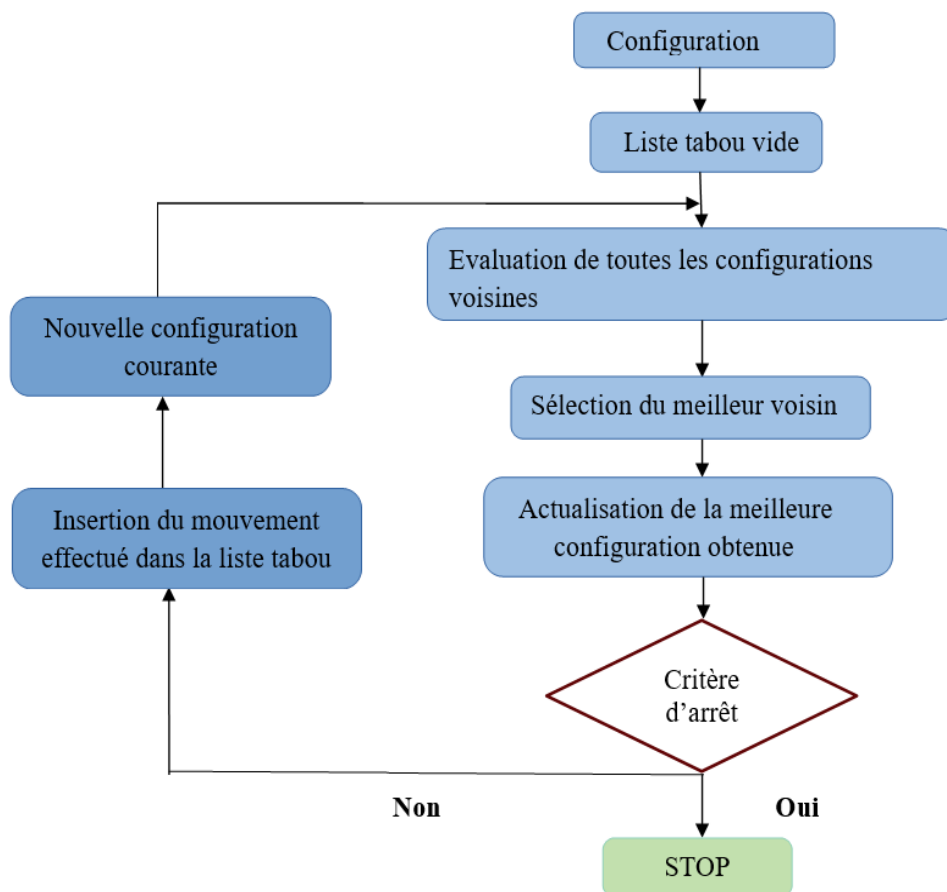


Fig. 2.4 – Organigramme illustrant le Fonctionnement de l'algorithme TS

Algorithme 2 : Recherche Taboue

```
 $l \leftarrow \text{longueurmaximaledelalistetaboue}$ 
 $n \leftarrow \text{numeroftweaksdesiredtosamplethegradient}$ 
 $S \leftarrow \text{solutioninitial}$ 
 $Best \leftarrow S$ 
 $L \leftarrow \{\}$ 
Insérer s dans L
tant que ( $Best$  est la meilleure)  $\cap$  ( $\text{nombre iter} = \text{max}$ ) faire
    si  $\text{longueur}(L) > l$  alors
        Défiler un élément de la liste L
    fin
     $r \leftarrow r'$  où  $r' \in N(s)$ 
    pour  $i \leftarrow 1$  à  $N - 1$  faire
         $w \leftarrow w'$  où  $w' \in N(s)$ 
        si  $w \notin L \cap (f(w) < f(r) \cup r \in L)$  alors
             $e \leftarrow w$ 
            si  $r \notin L \cap f(r) < f(s)$  alors
                 $s \leftarrow r$ 
                Enfiler r dans L
            fin
            si  $f(s) < f(Best)$  alors
                 $Best \leftarrow s$ 
            fin
        fin
    fin
fin
```

- c) **Recherche locale** : Pour cette méthode de recherche il suffit de tester itérativement de nouvelles solutions potentielles dans la région de la solution courante, et de prendre la meilleure dans le voisinage. La méthode est une généralisation de la méthode de la descente de gradient elle consiste à partir d'une solution s à choisir une solution s' dans un voisinage de s , noté $N(s)$. La nouvelle solution choisie est meilleure que la précédente sous la fonction objective. Cela nous permet d'explorer l'espace des combinaisons de proche en proche, en partant d'une combinaison initiale et en sélectionnant à chaque itération une combinaison voisine de la combinaison courante, obtenue en lui appliquant une transformation élémentaire jusqu'à la

convergence à un optimum local. L'algorithme décrivant le principe général de la recherche locale :

Algorithme 3 : Recherche Locale

```

s ← solutioninitial
tant que (Best est la meilleure)  $\cap$  (nombre iter=max) faire
    | r ← s' où  $s' \in N(s)$ 
    | si  $f(r) < f(s)$  alors
    | | s ← r
    | fin
fin

```

- d) **Recherche à voisinages variables(VNS)** : La recherche à voisinage variable (VNS : Variable neighborhood search) est une méta-heuristique proposée par Hansen et Mladenovic en 1997 [28,29]. Elle est basée sur le principe de changement systématique de voisinage durant la recherche (la performance des méthodes de descente). La procédure de VNS se compose de trois étapes : perturbation (shaking), recherche locale et déplacement. Cet algorithme est efficace si les structures de voisinage sont complémentaires en ce sens qu'un minimum local pour un voisinage n'en n'est pas nécessairement un pour un autre, ce qui veut dire simplement d'utiliser plusieurs voisinages successifs quand on se trouve bloqué dans un minimum local.

Algorithme 4 : Recherche à voisinages variables (VNS)

```

s ← solutioninitial
répéter
    | générer s', tel que  $s' \in N(s)$ 
    | s'' ← Appel(Recherche Locale)
    | si  $f(s'') < f(s)$  alors
    | | s ← s''
    | | K ← 1
    | sinon
    | | K = K + 1
    | fin
jusqu'à  $K = K_{Max}$ 

```

2.2.2.4 Méthodes évolutives (A population) :

Depuis le début des années 90, une autre famille d'heuristiques est devenue très populaire : les Méthodes Évolutives [36], s'inspirant de la théorie de l'évolution «darwinienne» tels que le croisement, la mutation et la sélection pour résoudre des problèmes divers. Contrairement à la Recherche Locale qui tente d'améliorer itérativement une solution courante. Les Méthodes Évolutives travaillent sur une population de solutions en appliquant un processus cyclique composé d'une phase de coopération et d'une phase d'adaptation individuelle qui se succèdent à tour de rôle. Dans la phase de coopération, les solutions de la population courante sont comparées entre elles, puis combinées, dans le but de produire de nouvelles solutions qui héritent des bons aspects de chaque membre de la population. Dans la phase d'adaptation individuelle, chaque solution dans la population peut évoluer de manière indépendante. On peut utiliser le même type de critère d'arrêt que dans la Recherche Locale, ou alors on peut décider de stopper une Méthode Évolutive dès que les solutions dans la population sont jugées trop similaires. Une description générale des Méthodes Évolutives est donnée ci-dessous :




Fig. 2.5 – Principe d'un algorithme évolutionnaire (EA) [3].

Le terme Evolutionary Computation englobe une classe assez large de méta-heuristiques qui ont été développés au début des années soixante, telles que les algorithmes génétiques [37], les stratégies d'évolution [38], la programmation évolutive [39], et la programmation génétique [40]

a) **Algorithmes génétiques(AG)** : développées par J. Holland en 1975 [37]

comme outils de modélisation de l'adaptation et qui travaillent dans un espace de chaînes de bits. Elles ont été largement utilisées et développées par Moscato en 1989 [41]. Cette classe s'inspire de la théorie de l'évolution et des règles de la génétique qui expliquent la capacité des espèces de s'adapter à leur environnement à l'aide de l'opérateur de mutation, alors que l'échange d'information est gouverné par un opérateur de reproduction et un opérateur de combinaison (ou croisement). L'algorithme ci-dessous décrit ce principe général, dont les principales étapes sont détaillées ci-après.

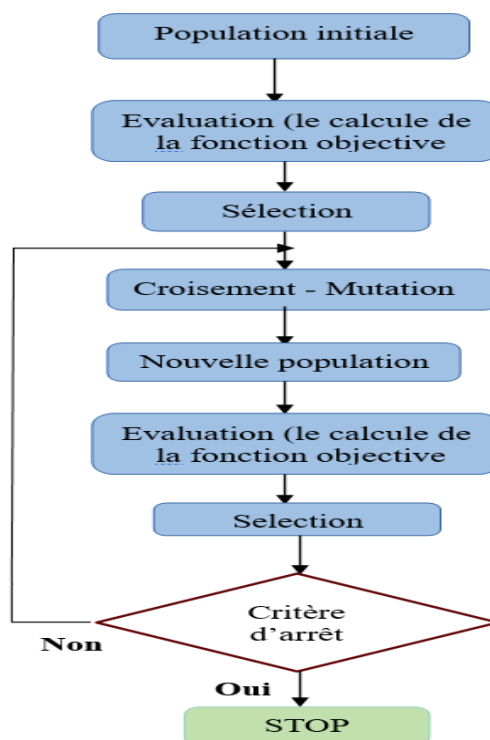


Fig. 2.6 – Organigramme d'un algorithme génétique

Algorithme 5 : Algorithme génétique

Résultat : la meilleure combinaison ayant appartenu à la population

Initialiser la population avec un ensemble de combinaisons de E

tant que critères d'arrêt non atteints **faire**

 Sélectionner des combinaisons de la population

 Créer de nouvelles combinaisons par croisement et mutation

 Mettre à jour la population

fin

- **Initialisation de la population :** en général, la population initiale est

générée de façon aléatoire, selon une distribution uniforme assurant une bonne diversité des combinaisons. Une solution initiale est de bonne qualité, celle qui nous permet de converger vers un optimum global dans le plus court délai possible.

Il est à noter que cette méthode est utilisée dans toutes les méta-heuristiques avec population.

- **Sélection** : cette étape consiste à choisir les combinaisons de la population qui seront ensuite croisées et mutées. Il s'agit là de favoriser la sélection des meilleures combinaisons, tout en laissant une petite chance aux moins bonnes combinaisons. Il existe de nombreuses façons de procéder à cette étape de sélection. Par exemple, la sélection par tournoi consiste à choisir aléatoirement deux combinaisons et à sélectionner la meilleure des deux (ou bien à sélectionner une des deux selon une probabilité dépendant de la fonction objectif).
- **Croisement** : est une opération de diversification. cette opération consiste à générer de nouvelles combinaisons, à partir des deux individus sélectionnés. Là encore, il existe de nombreux opérateurs de croisement. Une méthode simple consiste à choisir aléatoirement un point de croisement, à couper chaque combinaison parente en ce point, puis à reformer deux enfants en échangeant les parties composant les parents de part et d'autre du point de croisement.
- **Mutation** : cette opération consiste à modifier de façon aléatoire certains composants des combinaisons obtenues par croisement.
- **Mise à jour de la population** : cette étape consiste à remplacer certaines combinaisons de la génération précédente par certaines combinaisons issues des opérations de croisement et de mutation, formant de la sorte une nouvelle génération. Là encore, il existe différentes stratégies de remplacement, favorisant plus ou moins la diversité, et plus ou moins élitistes. On peut par exemple choisir de ne garder que les meilleurs individus, qu'ils soient issus de la nouvelle génération ou de l'ancienne, ou bien ne garder que les individus de la nouvelle génération, indépendamment de leur qualité.
- **Critères d'arrêt** : le processus d'évolution est itéré, de génération en génération, jusqu'à ce qu'une combinaison de qualité suffisante soit générée, ou bien jusqu'à ce qu'une limite de temps soit atteinte. On peut également utiliser des indicateurs de diversité (comme par exemple le taux de ré-échantillonnage ou la distance pair-à-pair) pour

arrêter le processus lorsque la population est devenue trop uniforme. On peut aussi limiter le nombre d'itération possible ou encore les probabilités d'application des opérateurs de croisement et de mutation.

- b) **L'optimisation des colonies de fourmis (ACO)** : est une technique d'intelligence artificielle qui s'inspire du comportement intelligent des fourmis lors de la recherche de nourriture. Cette méta-heuristique permet de trouver des solutions de haute qualité aux problèmes d'optimisation combinatoire. En raison de leur comportement de recherche de nourriture, les fourmis trouvent les chemins les plus courts entre leur nid et leur source de nourriture, en déposant sur la terre une substance chimique appelée phéromone. Cela forme une traînée de phéromone qui est utilisée pour la communication stigmergique. La présence d'une telle phéromone sur les trajectoires affecte la prise de décision des fourmis concernant les trajectoires choisies par elles. Les fourmis sélectionnent de manière probabiliste les chemins marqués par de fortes concentrations de phéromones ce qui permet aux fourmis de trouver le chemin le plus court vers la source de nourriture.

Algorithme 6 : L'optimisation des colonies de fourmis (ACO)

Résultat : la meilleure solution trouvée

// Initialisation

initialisation de phéromones et les paramètre avec des valeurs constantes

Construction de la solution initiale

tant que *condition d'arrêt non atteinte* **faire**

tant que *nombre de fourmis non atteint* **faire**

 Construction d'une solution selon la concentration de phéromone

 Mise à jour en ligne de la table des phéromones

fin

si *la meilleure solution trouvée par l'itération courante est meilleure que celles des itérations précédente* **alors**

 Mise à jour de la solution courante

fin

 Mise à jour hors ligne de la table des phéromones

fin

- **Solution initiale** : en général, la solution initiale est générée de façon aléatoire. Une solution est composée de plusieurs attributs définis selon

la nature du problème.

- **Initialisation de la table de phéromone** : la table de phéromone contient la concentration de phéromone pour tous les attributs possible d'une solution. Au départ tous les attributs ont une même concentration de phéromone.
- **Mise à jour de phéromone** :
 - **En ligne** : les attributs communs entre la solution courante et la meilleure solution vont être favoriser par une valeur constante supplémentaire.
 - **Hors ligne** : les attributs appartenant à la meilleure solution vont être favoriser par la valeur constante.

c) **L'algorithme à base de biogéographie (BBO)** BBO est un algorithme inspiré de la biogéographie, qui étudie la répartition géographique des organismes biologiques.

Tout comme GA et PSO qui sont basés sur la biologie, BBO est un algorithme basé sur une population dans lequel chaque population de solutions candidates est utilisée dans la procédure de recherche d'un optima global. BBO présente certaines caractéristiques communes avec l'algorithme d'optimisation, le GA. En GA, un individu de la population s'appelle un chromosome et a sa propre valeur de condition physique. De même, dans BBO, chaque individu est qualifié d'habitat et a son indice de qualité de l'habitat (HSI) pour évaluer sa qualité en tant que solution. Comme nous avons affaire à un problème de minimisation, un habitat à faible indice de sécurité d'impact représente une bonne solution et un habitat à haut indice de faiblesse est plutôt une solution médiocre. Chaque chromosome de GA est constitué de gènes, tandis que, pour BBO, chaque habitat est caractérisé par des variables d'indice de pertinence (SIV). L'AG compte deux opérateurs principaux : le croisement et la mutation. Pendant ce temps, chez BBO, les principaux opérateurs sont la migration et la mutation. L'opérateur de migration est composé d'émigration et d'immigration. Il est utilisé pour améliorer et faire évoluer les habitats (solutions au problème d'optimisation) de la population. Les fonctionnalités de solution (SIV) émigrent d'habitats à faible HSI (habitats d'émigration) vers des habitats à haut HSI (habitats d'immigration). Il existe différentes alternatives pour les processus de migration et de mutation de BBO. La manière dont nous implémentons ces deux opérateurs est expliquée en détail dans le prochain chapitre.

Algorithme 7 : L'algorithme à base de biogéographie (BBO)

Résultat : la meilleure solution ayant appartenu à la population

Générer aléatoirement un ensemble de solutions initiales (îles)

tant que *le critère d'arrêt n'est pas atteint* **faire**

 Évaluer la fitness (HSI) de chaque solution

 Calculer le nombre d'espèce S , le taux d'immigration λ et
 d'émigration μ pour chaque solution

Migration

Mutation : muter les individus au taux de mutation

 Remplacement de la population par les descendants

 Implémenter l'**élitisme**

fin

Dans le processus de migration (algorithme 8), quand une solution est sélectionnée pour être changée, nous utilisons le taux d'immigration λ pour décider si un SIV sera changé. Dans ce cas, nous utilisons le taux d'émigration μ pour décider quelle bonne solution migrera son SIV.

Cette algorithme sera suivit d'une figure qui illustre le fonctionnement de ce processus (figure 2.7)

Algorithme 8 : migration

pour $i \leftarrow 1$ à N **faire**

 Utiliser λ_i pour décider, de manière probabiliste, d'immigrer à X_i

si $\text{rand}(0, 1) < \lambda_i$ **alors**

pour $j \leftarrow 1$ à N **faire**

 Sélectionner un habitat d'émigration X_j avec une probabilité

$\alpha\mu_j$

si $\text{rand}(0, 1) < \mu_j$ **alors**

 Remplacer une variable de décision (SIV) choisie

 aléatoirement dans par la variable correspondante dans X_j

fin

fin

fin

fin

Où :

λ_k : est le taux d'immigration dans un habitat de k espèces

μ_k : est le taux d'émigration dans un habitat de k espèces.

E : est le taux maximal d'émigration.

I : est le taux maximal d'immigration. Supposons que nous avons une population de solutions candidates à un problème, représentées par des vecteurs (habitats $H_i, i = 1 \dots n$)

N : est le nombre maximum d'espèces.

k : est le nombre d'espèces.

Mutation : c'est le même principe qui est utilisé pour l'algorithme génétique.

Elitisme : cette méthode consiste à garder les meilleurs individus de chaque population. La méthode d'élitisme risque d'élaguer les individus de mauvaise qualité mais ça n'empêche pas de produire une population avec des résultats meilleurs ou au moins de créer des individus qui auront pu apporter de quoi créer de très bonnes solution dans les populations suivantes.




Fig. 2.7 – processus de migration de BBO

d) **Algorithmes mémétiques (algorithme de colonies de fourmis & d'essaim de particules)** : Le terme «algorithmes mémétiques» est apparu pour la première fois dans [41], introduit par Moscato en 1986. L'idée principale de ce genre d'algorithme est de rendre plus agressif un algorithme génétique par l'ajout d'une recherche locale en plus de la mutation.

La faible vitesse de convergence est la première observation provenant de l'implémentation de l'algorithme génétique. Pour cet effet Moscoto a pensé d'ajouter une recherche locale qui peut être une méthode de descente ou une recherche locale plus évoluée (recuit simulé ou recherche tabou par exemple). Cette recherche locale sera appliquée à tout nouvel individu ob-

tenu au cours de la recherche.

D'une vue globale, l'application de cette simple modification n'influe en rien sur le comportement de l'algorithme, mais cela peut apporter de profondes changements en ce dernier. Après avoir créé un nouvel individu à partir de deux parents sélectionnés, on applique une recherche locale et sous certaines conditions on applique un opérateur de mutation à cet individu. Les conditions peuvent être une certaine probabilité. Il est aussi possible d'ajouter un critère d'aspiration ou d'autres techniques plus évoluées à cet endroit.

Algorithme 9 : Simple Algorithme mémétique

Résultat : la meilleure solution ayant appartenu à la population

Initialisation : générer une population initiale P de solutions de taille

$$|P| = n$$

répéter

 Sélection : choisissez 2 solutions s et s' avec la technique voulue

 Croisement : combinez les solutions parentes s et s' pour former une solution enfant y

 Recherche locale : appliquer une procédure de recherche locale sur y sous certaines conditions

 Mutation : appliquer un opérateur de mutation sur y dans des conditions

 Choisir un individu y' à remplacer dans la population
 remplacer y' par y dans la population

jusqu'à critère d'arrêt satisfait

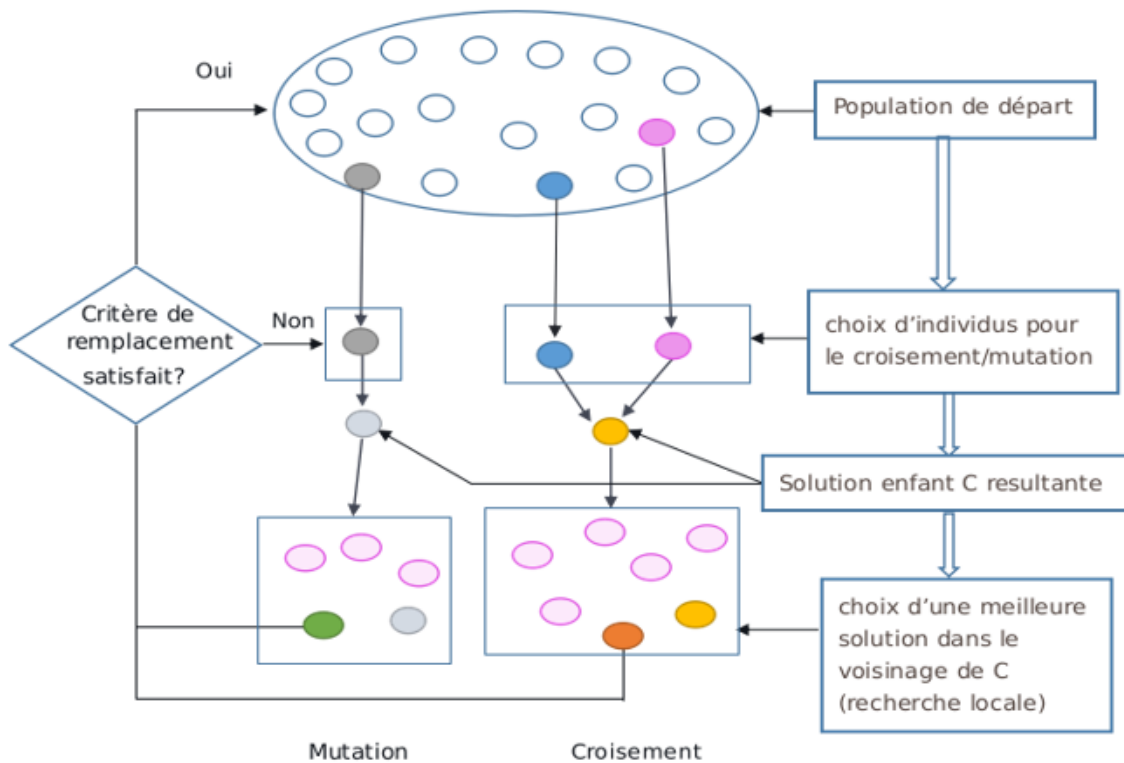


Fig. 2.8 – Schéma explicatif d'un algorithme mémétique

2.3 Conclusion

Nous avons présenté dans ce chapitre l'état de l'art des méta-heuristiques pour l'optimisation des problèmes Np-difficile. Plus de détails sur le problème de l'arbre dominant qui en est un, ainsi que les méthodes utilisées pour sa résolution seront mis au clair dans le prochain chapitre.

CHAPITRE 3

LE PROBLÈME DE L'ARBRE DOMINANT (DTP)

3.1 Introduction

Comme la gestion de l'énergie dans les réseaux de capteurs sans fil (RCSFs) est très exigeante, plusieurs chercheurs sont actuellement engagés non seulement dans le développement des technologies requises au niveau des différentes couches de la pile protocolaire des réseaux de capteurs, mais aussi pour la conception des méthodes et des algorithmes qui assurent une gestion meilleure.

Au cours de ces dernières années, les chercheurs sont arrivés à représenter un réseau sous forme d'un graphe G , où chaque capteur sera représenté par un nœud et la connexion entre deux nœuds est représentée par une arête. Néanmoins, cela ne résout pas les problèmes de routage pour la gestion d'énergie dans les RCSFs, alors ils ont pensé à la notion du plus court chemin dans G . Cette approche a donné naissance à un nouveau problème nommé le problème de ensemble dominant (Connected Dominating Set CDS).

Cette approche a été largement utilisée pour construire une ossature de routage dans les réseaux de capteurs [20, 42]. Elle se concentre sur les nœuds au lieu des arêtes afin de minimiser la consommation d'énergie. Tandis que l'énergie dissipée lors du routage des données est directement liée aux arêtes. Le problème de l'arbre dominant (Dominating Tree Problem ou DTP) a donc été formulé dans le but de pallier aux lacunes du CDS [5, 6] .

Dans ce chapitre, nous présenterons le problème de l'arbre dominant, puis nous synthétiserons quelques travaux effectués pour sa résolution, enfin nous clôturerons ceci par une conclusion.

3.2 Définition du problème

Le problème de l'arbre dominante nous incite à trouver un arbre de poids minimal DT. Le principe est que chaque réseau sans fil sera représenté par un graphe pondéré non orienté $G=(V,E,w)$, où V est l'ensemble des nœuds du réseau, E l'ensemble des liaisons de communication du réseau et w un poids non négatif attribué pour chaque arête $e=(u,v)$. Chaque nœud $v \in V$, est soit dans DT, soit adjacent à un nœud déjà dans DT. La complexité de la construction d'un arbre dominant est Np-hard.

D'autre part, la résolution du DTP peut générer une ossature de routage pour les protocoles de diffusion puisque chaque nœud n'a pas à construire son propre

arbre de diffusion, alors ils utilisent l'ossature virtuelle pour réduire la surcharge de message et le poids de l'ossature qui représente la consommation d'énergie minimisée. Comment régler le problème de l'arbre dominant (DTP) ?

3.3 Complexité et approximation

Le problème de l'arbre dominant (DTP) est une variante récente d'ensemble dominants en théorie des graphes. Il est prouvé qu'il est un problème NP-Hard [5, 6].

L'arbre de Steiner est souvent associé à des problèmes de conception de réseau. Le principe de conception de cet arbre est très proche du principe de conception de l'arbre dominant. Il consiste à construire un arbre de poids minimal r nommé DST, en veillant à ce qu'il y ait au moins un chemin allant de la racine à chaque nœud de l'ensemble D tel que D est un ensemble dominant minimal appartenant à V dans G .

Dans [5] il a été montré que le DTP peut être réduit au problème DST en un temps polynomial. Rappelons que l'algorithme de construction de DST avec la conservation du rapport de performance nous permet de l'appliquer au DTP de la façon suivante :

Dans le problème DT nous introduisons un sommet factrice v^* (un faux sommet) pour chaque sommet réel $v \in V$, puis nous ajoutons les arcs pour tous les voisins de v (y compris v lui-même) au nœud factice v , et fixons le poids à zéro pour toute arête nouvellement ajoutées. De même, pour les arêtes originales, l'arête est bidirectionnelle et le poids identique à celui du graphe original. Dans le nouveau graphe orienté $G' = (V', E', w')$, si nous choisissons un $v' \in V'$ arbitraire comme root r , et que tous les sommets factices soient des terminaux, nous pouvons obtenir un DST basé sur un algorithme DST existant [6] et obtenir ainsi un DT de G . Il est clair que la réduction est réalisée en temps linéaire. Cette réduction est illustrée sur la Figure 3.1.

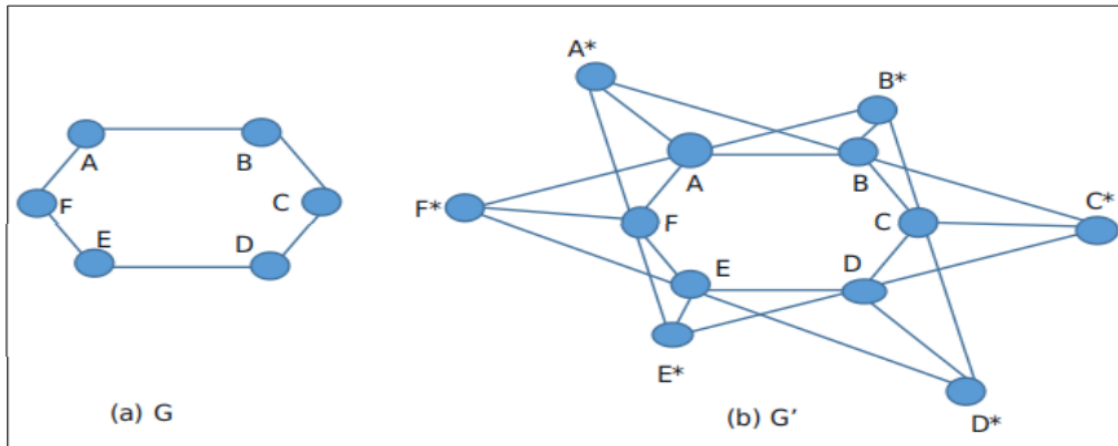


Fig. 3.1 – Exemple de réduction du graphe G en G'

Lemme 1 : Si r est dans le DT optimal, alors le DT introduit par DST aura le même poids optimal. En outre, l'utilisation de l'algorithme d'approximation pour le problème DST aura le même rapport d'approximation pour le problème DT [5].

Preuve : Supposons qu'il existe une arborescence dominante optimale DT^* , nous pouvons faire en sorte que tous les nœuds de DT^* apparaissent dans le DST. Puisque r est dans DT^* , pour chaque nœud de DT , au moins un de ses voisins doit être dans DT , et pour tout terminal, nous pouvons ajouter un front dirigé depuis ce voisin. Et nous savons que ces arêtes sont pondérées à zéro, de sorte que le poids de cette DST est égal à $w(DT^*)$. Supposons qu'il existe un DST optimal ST^* , alors nous avons $w(DT^*) \geq w(ST^*)$. En outre, pour un DST optimal, nous pouvons éliminer toutes ces arêtes pondérées par zéro. Étant donné que tous les nœuds terminaux ont un chemin allant de r à eux, chaque nœud aura au moins un de ses voisins figurant dans cet arbre, ce qui signifie qu'il s'agit d'un DT. Nous avons donc $w(ST^*) \geq w(DT^*)$. En conclusion, nous avons $w(DT^*) = w(ST^*)$. Cela implique à son tour que nous pouvons obtenir le même rapport de performances pour le problème DT que pour le DST [5].

Une approximation poly-logarithmique a été fourni par les auteurs dans [43]. L'algorithme qui nous permet d'obtenir le rapport de performance est le suivant :

Algorithme 10 : Recuit simulé

Données : un graphe général pondéré non orienté $G = (V, E, w)$

Résultat : Un DT de G

Initialiser une liste pour sauvegarder le DT et son poids

Trouver un sommet factice u en G avec un degré minimum

Transformer G en $G' = (V', E', w')$ en utilisant la technique de transformation

pour chaque nœud v où $(u, v) \in E$ **faire**

 Exécution de l'algorithme DST [43] dans G et définir v comme racine r pour obtenir un DT

 Sauvegarder le DT et son poids dans la liste

fin

Retourner le DT avec poids minimum dans la liste

L'algorithme 10 nous permet de transformer le DTP en DST. Puis nous pouvons appliquer l'algorithme dans [43] qui va nous permettre par la suite de résoudre le problème DST et de trouver une solution pour le DTP. Cela n'est possible que si le sommet racine r choisie dans l'algorithme 10 soit le meilleur choix (r doit être dans le DT optimal). Au final, nous pouvons revenir à l'état initial de notre graphe de départ en supprimant les nœuds factices ajoutés ainsi que leurs arêtes.

3.4 Notions de base

3.4.1 Arbre couvrant de poids minimal (MST) :

un graphe pondéré non orienté $G=(V,E,w)$, où V est l'ensemble des nœuds du réseau, E l'ensemble des liaisons de communication du réseau et W un poids non négatif attribué sur chaque arête $e=(u,v)$.

a) **Qu'est-ce qu'un arbre couvrant (Spanning Tree ST) ?**

un arbre couvrant d'un graphe G est un arbre qui s'étend à inclure tous les sommets de G .

b) **Qu'est-ce qu'un arbre couvrant de poids minimal (MST) ?**

Le coût de l'arbre couvrant est la somme des poids de toutes les arêtes de l'arbre. Il peut y avoir beaucoup d'arbres couvrant. L'arbre couvrant de poids minimal est l'arbre couvrant dont le coût est minimal parmi tous les arbres couvrant. Il peut également y avoir beaucoup d'arbres couvrant mi-

nimum.

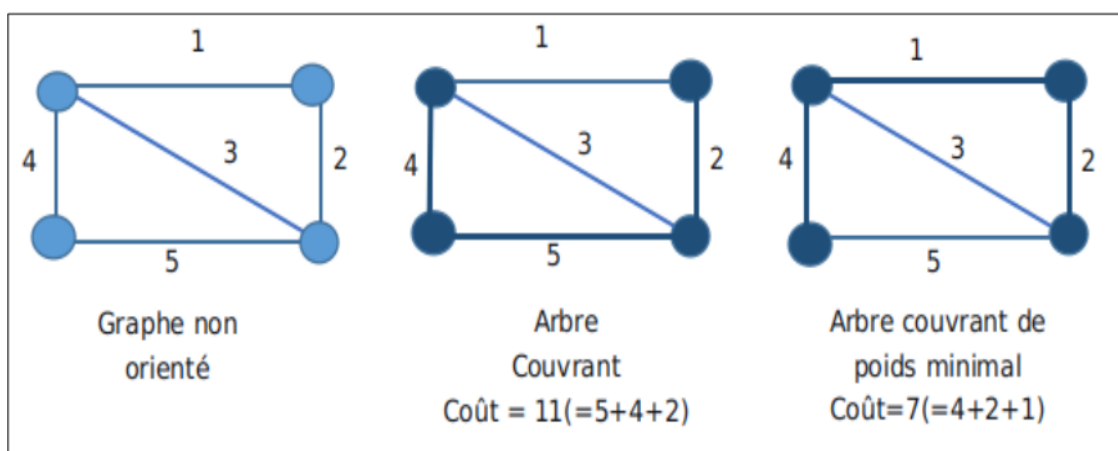


Fig. 3.2 – Exemple de réduction du graphe G en G'

Il existe deux algorithmes les plus réputés pour la construction d'un arbre couvrant de poids minimal : Kruskal et Prim. Nous allons nous contenter de l'algorithme de Prim car d'après [44], c'est l'algorithme le plus efficace.

Algorithme de Prim :

C'est un algorithme glouton qui tente de construire un arbre couvrant de poids minimal dans un graphe non orienté, connexe. Nous allons présenter dans ce qui suit l'algorithme de Prim ainsi qu'un exemple qui illustre le déroulement de ce dernier.

Algorithme 11 : Prim

Données : un graphe général pondéré non orienté $G = (V, E, w)$

Résultat : Un arbre couvrant de poids minimal T

// Initialisation de T

sommets \leftarrow un sommet de G qu'on choisit

arêtes \leftarrow aucune

répéter

 Trouver toutes les arêtes de G qui relient un sommet de T et un sommet extérieur à T

 Sélectionner l'arête ayant le plus petit poids parmi l'ensemble des arêtes trouvées

 Ajouter à T cette arête et le sommet correspondant

jusqu'à tous les sommets de G soient dans T

Retourner T




Fig. 3.3 – illustration de l'algorithme de Prim

3.4.2 L'élagage (Pruning) :

Cette méthode est apparue pour la première fois dans [5, 6] et a été améliorée dans [45].

Dans [45], la fonction de pruning consiste à vérifier si un sommet $v \in DT$ de degré un peut être élagué sans que DT soit non connexe. Si cela est vérifié, ce nœud alors va devenir non dominant et l'arête incidente peut également être retirée de DT , ce qui réduit par la suite le poids de DT . Dans un second lieu, cette fonction vérifie tous les sommets de DT dans l'ordre FIFO (First In First Out). Si le degré d'un sommet dominant v est égale à un, il est vérifié si tous les sommets adjacents à v sont également adjacents à d'autres sommets dominants dans DT . Si c'est le cas supprimer ce sommet de DT et l'arête incidente aussi. Cette méthode de pruning est largement différente que celle utilisée dans [5] dans laquelle un arbre couvrant est d'abord construit et, par conséquent, tous les sommets feuilles peuvent être élagués sans autre vérification.

3.5 Les travaux relatifs

Le problème de l'arbre dominant est apparu récemment (2008). Il a été introduit par [6] pour la construction d'une ossature de routage pour les réseaux sans fil avec une consommation d'énergie minimal, ce qui justifie le manque de

la littérature pour ce problème.

La consommation d'énergie est prise en compte qu'au niveau des nœuds et non les arêtes. En réalité, l'énergie consommée par chaque arête affecte directement la consommation d'énergie d'un système de routage. Par conséquent, pour minimiser la consommation d'énergie d'un système de routage, nous devons prendre en compte l'énergie consommée par chaque arête [45].

Au meilleur de notre connaissance, aucune formulation de programmation en nombres entiers n'a été étudiée dans la littérature pour le DTP autre que celle classique introduite dans [5].

En 2010, puisque le problème de l'arbre dominant est NP-hard, Yilin Shen · My T. Thai ont fait l'approximation du DTP au problème DST [5]. Cependant, la complexité temporelle est assez élevée, du fait que la construction d'un DST entraîne généralement une longue durée d'exécution. De ce point de vue, une heuristique peu complexe en temps est souhaitable ce qui a orienté la littérature sur le DTP vers les algorithmes heuristiques, tels que la recherche par voisinage variable (VNS) et des algorithmes méta-heuristiques, tels que les algorithmes génétiques, la colonie d'abeilles artificielles et les colonies de fourmis. Nous allons considérer pour la suite un graphe $G = (V, E, w)$, non orienté, pondéré, où : V est l'ensemble des sommets et E est l'ensemble des arêtes du graphe G .

3.5.1 L'heuristique pour le problème de l'arbre dominant (H_DT)

En 2013, Shyam Sundar et Alok Singh proposent un nouvel algorithme heuristique (H_DT) pour la construction d'un arbre dominant DTP [45]. Entre autre, un arbre couvrant minimal est construit sur le sous-graphe de G induit par l'ensemble des sommets dominants de DT à l'aide de l'algorithme de Prim [44]. De cette façon, le poids total de DT peut être réduit davantage. La raison est que même après le pruning, le poids total de DT peut ne pas être minimum en raison de la sélection d'arêtes incorrectes lors de la construction de DT. Sur un ensemble donné de sommets dominants, de nombreux arbres dominants peuvent être construits en G . De toute évidence, un arbre dominant obtenu à l'aide de l'algorithme de Prim aura un coût minimum parmi tous ces arbres dominants. Après cela, la procédure d'élagage est à nouveau appliquée, puis un arbre couvrant minimal est à nouveau construit sur le sous-graphe de G induit par l'ensemble des sommets dominants de DT à l'aide de l'algorithme de Prim. Dans ce qui suit nous allons donner le pseudo-code de l'heuristique H_DT et

expliquer brièvement son fonctionnement :

Algorithme 12 : pseudo-code H_DT

Données : un graphe général pondéré non orienté $G = (V, E, w)$
Résultat : sortie : un arbre dominant $DT \subseteq E$
// Initialise DT
 $DT \leftarrow \emptyset$
pour chaque sommet $i \in V$ **faire**
| Mark[i] $\leftarrow 0$
fin
Calcule les chemins les plus courts entre toutes les paires de sommets de G
Triez toutes les arêtes de E en ordre non décroissant en fonction de leur poids
tant que tous les sommets de V ne sont pas marqués **faire**
| Sélectionnez une arête non sélectionnée e_{ij} avec un coût minimal, dont au moins
| un point d'extrémité n'est pas marqué
| **pour** chaque sommet v adjacent à i ou j **faire**
| | Mark[v] $\leftarrow 1$
| **fin**
| **si** $DT = \emptyset$ ou e_{ij} est adjacent à une arête dans DT **alors**
| | $DT \leftarrow DT \cup \{e_{ij}\}$
| **sinon**
| | Trouver le chemin le plus court ST reliant DT et $\{i, j\}$
| | $DT \leftarrow DT \cup ST \cup \{e_{ij}\}$
| **fin**
| **pour** chaque sommet v en ST **faire**
| | Mark[v] $\leftarrow 1$
| | **pour** chaque sommet k adjacent à v **faire**
| | | Mark[k] $\leftarrow 1$
| | **fin**
| **fin**
fin
Appliquer la procédure d'élagage sur DT
Reconnectez les sommets dominants de DT en y construisant un arbre couvrant de
poids minimal
Appliquer l'élagage sur le DT
Reconnectez les sommets dominants de DT en y construisant un arbre couvrant de
poids minimal
Retourner DT

Cette heuristique se décompose en deux phases principales. La première phase est la phase d'initialisation, où le chemin le plus court entre toute paire de nœuds est calculé.

L'ensemble des sommets est étiqueté à "non marqué" et l'ensemble d'arêtes constituant DT est égale à l'ensemble vide. Ensuite, une phase itérative commence, où, à chaque itération, une arête e_{ij} de poids minimal avec au moins une

extrémité "non marquée" est choisie. Les voisins des extrémités de l'arête ajoutée seront "marqués". Une vérification est ensuite effectuée pour déterminer si l'arête e_{ij} est adjacente à DT ou non. Si ce n'est pas le cas, alors un chemin de coût minimal est déterminé pour établir un lien entre le DT partiellement construit et l'arête sélectionnée. Les arêtes constituant ce dernier sont ajoutés à DT et les nœuds appartenant à ce chemin ainsi que leurs voisins "non-marqués" seront "marqués". Dès que tous les sommets dans V seront marqués (condition d'arrêt vérifiée), la procédure d'élagage suivie de l'algorithme de Prim sont appliqués.

En outre, Shyam et Alok travaillent sur deux approches méta-heuristiques qui donnent des résultats satisfaisants, et ils ont essayé d'améliorer cet heuristique dans les années qui suivent.

3.5.2 Colonie d'abeilles artificielle pour le DTP (ABC_DT)

L'algorithme de colonie d'abeilles artificielles ou Artificial Bee Colony (ABC) a été introduit par Dervis Karaboga en 2005 [46] et développé depuis 2005 par Karaboga et Basturk [47] pour les problèmes d'optimisation continue. C'est un algorithme à population, d'inspiration naturaliste, basé sur le butinage des abeilles.

a) **Génération de la solution initiale :**

C'est un processus itératif pour générer des solutions initiales (arbres dominants) faisables, où à chaque itération, pour une probabilité P , une arête de poids minimal est choisie pour le nœud de départ qui a été choisi lui aussi aléatoirement sinon l'arête est choisie aléatoirement selon la méthode de sélection de roulette (wheel) afin de maintenir un équilibre entre qualité et diversité de la solution. A ce stade, un arbre dominant du graphe G est construit. Puis, la procédure d'élagage (décrite dans la section 3.2) est appliquée à DT de manière répétée jusqu'à ce qu'il ne soit plus possible d'élaguer un sommet dominant de degré un. Par la suite, la "procédure MST" (de la section 3.1) est appliquée sur la solution obtenue.

b) **Probabilité de sélectionner une source alimentaire :**

C'est à travers la méthode de sélection de "tournoi" dite "Binary Tournament Selection Method" (BTS), que les abeilles Onlooker (spectateurs) choisissent une solution de la population. Avec la probabilité b_t , la meilleure

est choisie, sinon la pire solution est sélectionnée avec probabilité 1-bt.

Algorithme 13 : Pseudo-code de ABC

```

Générer  $ne$  solutions aléatoires  $E_1, E_2, \dots, E_{ne}$ 
 $MeilleureSol \leftarrow$  meilleure solution parmi  $E_1, E_2, \dots, E_{ne}$ 
tant que La condition de terminaison est non satisfaite faire
    pour Chaque abeille employée  $i$  dans  $ne$  faire
         $E' \leftarrow$  determination_d_une_solution_voisine( $E_i$ )
        si  $E'$  est meilleure que  $E_i$  alors
             $E_i \leftarrow E'$ 
        sinon
            si  $E_i$  n'a pas changé après un nombre limité d'itérations alors
                Remplacer  $E_i$  avec une solution générée aléatoirement
            fin
        fin
        si  $E'$  est meilleure que  $MeilleureSol$  alors
             $MeilleureSol \leftarrow E_i$ 
        fin
    fin
    pour Chaque abeille onlooker  $i$  dans  $n_0$  faire
         $s_i \leftarrow$  methode de sélection de tournoi binaire ( $E_1, E_2, \dots, E_{ne}$ )
         $O_{ni} \leftarrow$  determination_d_une_solution_voisine( $E_{s_i}$ )
        si  $O_{ni}$  est meilleure que  $MeilleureSol$  alors
             $MeilleureSol \leftarrow O_{ni}$ 
        fin
        si  $O_{ni}$  est meilleure que  $E_{s_i}$  alors
             $E_{s_i} \leftarrow O_{ni}$ 
        fin
    fin
fin

```

c) Détermination du voisinage d'une source alimentaire :

La détermination d'une solution voisine se fait selon deux procédures qui s'excluent mutuellement. Après qu'une solution s soit créée, une copie de cette dernière est affectée à s' . Après cela, Avec une probabilité P , une solution voisine est générée en appliquant la méthode PDE, qui supprime une arête de façon aléatoire sinon la méthode PANDV est appelée pour ajouter un sommet aléatoirement. L'application de ces deux méthodes fait que la solution devient infaisable, ce qui fait que chacune d'entre elles procède différemment pour la rendre faisable. Le pseudo-code de l'algorithme de détermination de voisinage d'ABC_DT est représenté dans l'Algorithme 14 ci-dessous.

Algorithme 14 : Pseudo-code de détermination d'une solution voisine

Données : Une solution s

Résultat : Une solution voisine s

Créer une copie s' de s

si $u_{01} < q_1$ **alors**

 | Appliquer la procédure PDE sur s

sinon

 | Appliquer la procédure PANDV sur s

fin

Appliquer la procédure pruning sur s

Reconnecter les sommets dominants de s' en construisant un arbre de poids minimum sur eux (MST)

Appliquer la procédure pruning sur s

Reconnecter les sommets dominants de s' en construisant un arbre de poids minimum sur eux (MST)

3.6 Algorithme génétique stationnaire

C'est un algorithme génétique, dit "stationnaire" (Steady State Genetic Algorithm SSGA) [22], SSGA utilise la méthode de remplacement de la population à l'état d'équilibre [48]. Cet algorithme commence par la sélection de deux parents, exécute le croisement et la mutation pour générer une solution (enfant) qui remplace le pire individu de la population. Dans ce qui suit, nous allons présenter les principales caractéristiques de cet algorithme.

a) **Génération de la solution initiale :**

C'est un processus itératif, qui procède par l'ajout des arêtes de manière aléatoire dans le but d'avoir un arbre dominant. Après que cet arbre soit créé les deux procédures "pruning" de la section 3.2 et "MST" (voir la section 3.1) sont appliquées.

b) **Fitness :**

La Fitness d'une solution est la même que la fonction objectif d'une solution, telle que la valeur de la fonction objectif est la somme des poids des arcs de la solution.

c) **La sélection :**

La méthode de sélection de tournoi binaire (BTS). Cette méthode est utilisée pour la sélection d'un individu pour la mutation. Elle est utilisée aussi

deux fois de façon consécutive pour la sélection de deux chromosomes (individus) comme parents pour l'opération de croisement (cross-over) ; avec la probabilité P , l'individu avec une meilleure fitness est sélectionné, sinon, c'est le plus mauvais qu'il l'est (avec la probabilité $1-P$).

d) Le croisement (cross-over) :

Afin de générer une solution enfant C , qui est initialement vide, deux parents p_1 et p_2 sont sélectionnés à travers la méthode BTS.

Les sommets constituant la solution enfant seront choisis, en alternance, des deux ensembles des nœuds dominants des deux parents. En effet, un sommet ne sera rajouté que s'il n'existe pas déjà dans C . Maintenant, il y a une vérification sur l'existence d'une arête reliant le sommet choisi à l'arbre partiellement construit. Si c'est le cas, alors il est ajouté à C et est étiqueté à marqué ainsi que tous ses voisins. Sinon, un chemin optimal, appelé chemin potentiel, est calculé en fonction du nombre de nœuds non couverts appartenant au chemin sur le coût de celui-ci. En effet, ce chemin vise à maximiser le nombre de nœuds à rajouter dans C . De plus, cela permet d'éviter un opérateur réparateur et d'assurer d'avoir directement un arbre dominant de bonne qualité. Ce processus itératif est répété jusqu'à ce que tous les sommets soient "marqués".

e) Mutation :

Cette partie commence par la sélection d'une solution initiale en utilisant la méthode BTS. Un petit ensemble V_m de sommets non dominants est sélectionné aléatoirement de V/C . Itérativement, un sommet $v_s \in V_m$ est de degré 1 dans G et ayant un chemin de coût minimal avec un sommet $v_c \in C$. Cette procédure se poursuit jusqu'à ce que V_m devient vide. L'algorithme de Prim est ensuite appliqué à l'ensemble de sommets dominants de C .

f) Politique de remplacement :

Dans cette politique de remplacement, l'unicité de la solution enfant C , nouvellement créée, est examinée par rapport aux individus de la population. Dans le cas où C se révèle être différent de tous les individus de la population, alors il remplace le plus mauvais d'entre eux, sinon, il est rejeté.

Algorithme 15 : Pseudo-code de l'algorithme SSGA

Générer une population (popsize) de solutions $s_1, s_2, \dots, s_{pop_size}$ aléatoirement

$MeilleureSol \leftarrow$ La meilleure solution de la population

tant que La condition de terminaison est non satisfaite **faire**

si $u_{01} < p_c$ **alors**

$p_1 \leftarrow$ méthode de sélection de tournoi binaire $s_1, s_2, \dots, s_{pop_size}$

$p_2 \leftarrow$ méthode de sélection de tournoi binaire $s_1, s_2, \dots, s_{pop_size}$

 Enfant \leftarrow Opérateur de Croisement (p_1, p_2)

sinon

$p_1 \leftarrow$ méthode de sélection de tournoi binaire $s_1, s_2, \dots, s_{pop_size}$

 Enfant \leftarrow Opérateur de Mutation (p_1)

fin

si Enfant est un DT partiel **alors**

 Appliquer procédure de réparation sur Enfant

fin

 Appliquer la procédure pruning sur le DT de Enfant

 Appliquer l'algorithme de Prim pour construire un arbre de poids minimal sur le sousgraphe de G induit par l'ensemble des sommets dominants de DT

 Appliquer la procédure pruning sur la DT de Enfant

si Enfant est meilleure que $MeilleureSol$ **alors**

$MeilleureSol \leftarrow$ Enfant

fin

 Appliquer la politique de remplacement

fin

Retourner $MeilleureSol$

3.7 L'algorithme évolutionnaire avec mutation guidée EA/G

L'algorithme évolutionnaire avec mutation guidée (Evolutionary algorithm with guided mutation [49]) est relativement un nouveau membre de la classe des algorithmes évolutionnaires. Il a été développé par Zhang et al. (2005) [49] pour surmonter les inconvénients de deux algorithmes évolutifs, à savoir algorithmes génétiques (GAs) et estimation d'algorithmes de distribution (EDAs). Il est dit hybride car il utilise les caractéristiques des deux algorithmes cités précédemment.

En effet, Les GAs génère une progéniture à partir des parents sélectionnés en appliquant les opérateurs génétiques tels que le croisement et la mutation. Ces algorithmes n'utilisent que les informations de localisation des solutions et ne font pas usage des informations globales sur l'espace de recherche qui peuvent être collectées en gardant la trace de toutes les solutions générées depuis le

début de l'algorithme. Dans ce contexte, "l'information de localisation d'une solution" revient à dire, l'information qui peut identifier de façon unique une solution dans l'espace de recherche de toutes les solutions. Par exemple, dans le cas du DTP, l'ensemble des arêtes formant le DT constitue son information de localisation car cette dernière peut l'identifier de façon unique.

Par ailleurs, les EDAs ne s'appuient que sur un modèle de probabilité pour générer une solution.

Le modèle de probabilité caractérise la distribution des solutions potentielles dans l'espace de recherche. Ce dernier, est mis à jour à chaque génération en utilisant des informations globales sur l'espace de recherche extraites des individus de la génération courante. Une solution est générée en se basant sur ce modèle de probabilité. Contrairement aux GA, les EDA n'utilisent pas directement les informations de localisation des solutions [50].

Pour conclure EA/G utilise un opérateur de mutation, appelé mutation guidée (GM), pour générer des descendants (solutions). La mutation guidée génère une nouvelle solution tenant compte à la fois des informations de localisation relatives à la solution mère ainsi que des informations statistiques globales relatives à l'espace de recherche. En d'autres termes, la génération d'une solution se fait par l'échantillonnage d'un modèle de probabilité caractérisant les informations statistiques globales et en copiant des éléments à partir de son parent.

EA/G hybride pour DTP (EA/G-MP)

Cette méthode s'inspire de l'approche de Zhang et al. (2005)[49] pour le problème de la clique maximale (MCP) et est développée en 2014 par les mêmes chercheurs. Les résultats obtenus par EA/G ont été améliorés par cette nouvelle méthode grâce à l'utilisation des deux procédures à savoir la reconnexion des nœuds de la solution via un MST (minimum spanning tree) et un opérateur d'élitage. Néanmoins, chacune de ces procédures est appliquée deux fois dans l'ordre $\text{MST} \rightarrow \text{Pruning} \rightarrow \text{MST} \rightarrow \text{Pruning}$.

Pour commencer EA/G-MP, nous devons définir les voisins de chaque nœud $v \in V$ et de calculer le chemin le plus court entre toute paire de nœuds. Avant de passer aux caractéristiques de l'algorithme, nous présentons dans ce qui suit un pseudo-code pour la procédure « pruning » pour cette approche suivie d'une explication pour ce dernier :

Algorithme 16 : Pseudo-code de la procédure pruning

```
 $R_n \leftarrow \{v : v \in DN \text{ et } |ON(v) \cap DN| = 1 \text{ et } CN(v) \subseteq (\cup_{u \in DN \setminus \{v\}})\}$ 
tant que  $R_n \neq \emptyset$  faire
     $DN \leftarrow DN \setminus \{v\}$ 
     $R_n \leftarrow \{v : v \in DN \text{ et } |ON(v) \cap DN| = 1 \text{ et } CN(v) \subseteq (\cup_{u \in DN \setminus \{v\}})\}$ 
fin
Retourner DN
```

Puisque le rôle de la procédure d'élagage consiste à éliminer les nœuds redondants dans l'arbre dominant. Pour cela, Cette procédure commence tout d'abord à sélectionner tous ces nœuds où le degré de chaque nœud v dans DN est égal à un et tous les nœuds voisins non dominants du nœud v sont couverts par d'autres nœuds dominants (autres que le nœud v) dans DN . Puis, un processus itératif commence : lors de chaque itération, un nœud de l'ensemble R_n est sélectionné (la sélection se fait selon l'ordre FIFO) et est supprimé de DN ainsi que de R_n .

De plus, tout en construisant un arbre dominant, la convention suivie, est celle où : un nœud prend la couleur BLANCHE s'il n'est pas un nœud dominant et n'est pas adjacent à un nœud dominant, GRISE si ce nœud est adjacent à un nœud dominant mais il ne l'est pas ,et un nœud appartenant à l'arbre est supposé avoir la couleur NOIRE. Initialement, tous les nœuds sont supposés avoir la couleur BLANCHE. Lorsque la construction de l'arbre dominant est terminée, les nœuds appartenant à l'arbre auront la couleur NOIRE et tous les autres nœuds (non dominants) auront la couleur GRISE.

a) Solution initiale :

Avant de présenter cette méthode commençons à définir quelques variables utilisées : W_n : ensemble de nœuds BLANCs ($W_n = V$ Initialement). I_u : l'ensemble des nœuds non dominants. nb : Ensemble de nœuds BLANCs voisins à v i.e. : $nb = ON(v) \cup W_n$. La méthode de génération de solution initiale est la même que celle utilisée dans Sundar et Singh (2013)(ABC_DT) [45] en portant deux modifications : La première, est que seuls les arrêtes e_{vu} sont considérés où $u \in I_u$ a au moins un voisin BLANC, c'est-à-dire où $|ON(u) \cap W_n| \geq 1$. La deuxième modification, est qu'avec la probabilité $1 - \phi$, nous sélectionnons les arrêtes uniformément au hasard au lieu d'utiliser la méthode de sélection de ABC_DT.

Algorithme 17 : Pseudo-code de la solution initiale de EA/G-MP

Initialement tous les nœuds dans V sont colorés en BLANC
 $W_n \leftarrow V$ $DT \leftarrow \emptyset$ $DN \leftarrow \emptyset$ $I_u \leftarrow \emptyset$
 $v \leftarrow \text{Random}(W_n)$
 $DN \leftarrow DN \cup \{v\}$
Mettre v NOIR
 $nb \leftarrow ON(v) \cap W_n$
 $W_n \leftarrow W_n \setminus (nb \cup \{v\})$
Mettre tous les nœuds $\in nb$ GRIS
 $I_u \leftarrow nb$
tant que $W_n \neq \emptyset$ **faire**
 Générer un nombre aléatoire u_{01} tel que $0 \leq u_{01} \leq 1$
 si $u_{01} < \phi$ **alors**
 $(v, u) \leftarrow \text{argument } v \in DN, \{u \in I_u | ON(u) \cap W_n| \geq 1\} w(v, u)$
 sinon
 $v \leftarrow \text{Random}(DN)$
 $u \leftarrow \{u : \text{Random}(I_u) \text{ et } |ON(u) \cap W_n| \geq 1\}$
 fin
 $DT \leftarrow DT \cup \{e_{v,u}\}$
 $DN \leftarrow DN \cup \{u\}$
 Mettre u NOIR
 $I_u \leftarrow I_u \setminus \{u\}$
 $nb \leftarrow \{u : u \in ON(u) \cap W_n\}$
 Mettre tous les nœuds nb GRIS
 $I_u \leftarrow I_u \cup nb$
 $W_n \leftarrow W_n \setminus nb$
fin
Appliquer la procédure pruning sur les nœuds dans DT
Reconnecter les nœuds dans DT via MST
Retourner DT

b) Initialisation et mise à jour du vecteur de probabilités

Le vecteur de probabilité est défini comme suit : $p = p_1, p_2, \dots, p_{|V|}$ $[0, 1]^{|V|}$, où $|V|$ est le nombre de nœuds dans l'ensemble V (nombre de nœuds dans le graphe G), p est la probabilité que le nœud $v \in V$ soit présent dans un arbre dominant. Ce vecteur est initialisé avec le rapport entre le nombre de solutions initiales contenant ce nœud et le nombre total de solutions initiales. Le pseudo-code est présenté dans l'algorithme 18.

Algorithme 18 : Pseudo-code de l'initialisation du vecteur de probabilités de EA/G-MP.

$nv \leftarrow$ nombre de solutions initiales contenant le nœud $v, \forall v \in V$;
 $p_v \leftarrow \frac{nv}{Np}, \forall v \in V$

A chaque génération g , un ensemble parent "parent (g)" est formé en sé-

lectionnant les meilleures solutions L dans la population actuelle (g). Une fois que le parent (g) est formé, il est utilisé pour mettre à jour le vecteur de probabilité p . Le pseudo-code pour la mise à jour du vecteur de probabilité est donné dans l'algorithme 19.

Algorithme 19 : Pseudo-code de la mise à jour du vecteur de probabilités de EA/G-MP.

$nv \leftarrow$ nombre de solutions initiales contenant le nœud $v, \forall v \in V$;

$p_v \leftarrow (1 - \lambda)p_v + \lambda \frac{nv}{L}, \forall v \in V$

où : $\lambda \in [0, 1]$ est le taux d'apprentissage ; plus λ est grand, plus la contribution des solutions dans parent (g) est grande. nv : Le nombre total de solution contenant dans le parent (g).

c) **Opérateur de mutation guidée GM**

L'opérateur GM utilise à la fois les informations statistiques globales stockées sous la forme du vecteur de probabilité p et les informations de localisation de la solution parent pour générer de nouveaux individus. Le pseudo-code de l'opérateur GM est présenté dans l'algorithme 20.

où $\beta \in [0, 1]$ est un paramètre ajustable et DT est un nouvel arbre dominant construit par l'opérateur GM et dont les nœuds sont soit choisis aléatoirement selon le vecteur de probabilité p , soit ils sont copiés à partir de la solution mi de la population courante.

Le choix des nœuds à partir de mi peut aider à améliorer la qualité de la solution vu que celle-ci fait parti des meilleures solutions M , cependant, l'utilisation du vecteur de probabilités permet une meilleure diversification en ajoutant les nœuds les moins utilisés à travers les générations.

Algorithme 20 : Pseudo-code de GM

Mettre la couleur de tous les nœuds dans V à BLANC

$DT \leftarrow \emptyset$

pour nœud $v \in V$ dans un ordre quelconque **faire**

 Générer un nombre aléatoire r_1 tel que $0 \leq r_1 \leq 1$

si $r_1 < \beta$ **alors**

 Générer un nombre aléatoire r_2 tel que $0 \leq r_2 \leq 1$

si $r_2 < p_v$ Et ((v est BLANC) Ou (v est GRIS avec au moins un voisin BLANC))

alors

 Trouver le chemin le plus court SP entre le nœud v et un nœud u dans DT

 Ajouter toutes les arêtes de SP dans DT

 Colorer en NOIR tous les nœuds dans le chemin SP

 Colorer en GRIS tous les nœuds voisins BLANCs des nœuds sur le chemin SP

fin

sinon

si v est un nœud dominant dans m i et v est GRIS avec au moins un voisin BLANC **alors**

 Trouver le chemin le plus court SP entre le nœud v et un nœud u dans DT

 Ajouter toutes les arêtes de SP dans DT

 Colorer en NOIR tous les nœuds dans le chemin SP

 Colorer en GRIS tous les nœuds voisins BLANCs des nœuds sur le chemin SP

fin

fin

fin

Retourner DT

L'opérateur de mutation GM ne garanti pas la faisabilité de la. Pour cette raison, toutes les solutions infaisables générées par cet opérateur sont traitées par un opérateur de réparation de façon à ce qu'elles deviennent réalisables.

- d) **Opérateur de réparation** : L'opérateur de réparation s'applique uniquement sur une solution infaisable générée par l'opérateur GM. Car de l'application de ce dernier, peut résulter des nœuds non couvrants. Pour résoudre ce problème, l'opérateur de correction procède comme suit :

soit U_{cn} l'ensemble des nœuds non couvrants (blancs) restants. Tous d'abord, un nœud contenant le nombre le plus élevé de nœuds voisins blancs dans la liste U_{cn} est sélectionné. Si aucun des nœuds de l'ensemble U_{cn} n'a des nœuds voisins BLANCs, le nœud ayant l'indice le plus bas est sélectionné à partir de U_{cn} , ce nœud est nommé i . Après cela, le chemin le plus court entre le nœud i et l'arbre partiellement construit DT est calculé, et toutes

les arêtes de ce dernier sont ajoutées dans DT. De même, les nœuds de ce chemin sont recolorés en NOIR (si ce n'est pas déjà fait) et leurs nœuds voisins en GRIS. Tous ces nœuds NOIR et GRIS sont ensuite supprimés de l'ensemble U_{cn} . Ce processus itératif est répété jusqu'à ce que U_{cn} devient vide. Le pseudo-code de l'opérateur de réparation est donné dans l'Algorithme 21 suivant :

Algorithme 21 : Pseudo-code de l'opérateur de réparation

```

tant que  $U_{cn} \neq \emptyset$  faire
     $v \leftarrow \text{argmax}_{u \in U_{cn}} (wd(u) > 0)$ 
    si  $v \neq \emptyset$  alors
        | Sélectionner un nœud  $v$  avec le plus petit index de  $U_{cn}$  ;
    fin
    Trouver le chemin le plus court SP entre le nœud  $v$  et un nœud  $u$  dans DT
    Ajouter toutes les arêtes de SP dans DT
    Colorer en NOIR tous les nœuds dans le chemin SP
    Colorer en GRIS tous les nœuds voisins BLANCs des nœuds sur le chemin SP
    Enlever tous les nœuds NOIRs et GRIS de  $U_{cn}$ 
fin
Retourner DT

```

Le pseudo-code de l'approche EA/G-MP pour DTP est donné dans l'algorithme 22.

Algorithme 22 : EA/G-MP pour DTP

A la génération $g \leftarrow 0$, une population initiale $\text{pop}(g)$ qui consiste en N p solutions est générée aléatoirement

Initialiser le vecteur de probabilités p pour tous les nœuds en utilisant l'Algorithme 18
tant que *La condition de terminaison est non satisfaite* **faire**

 Sélectionner les L meilleures solutions de $\text{pop}(g)$ pour former un ensemble parent $\text{parent}(g)$, puis mettre à jour le vecteur de probabilités p en utilisant l'Algorithme 19

 Appliquer l'opérateur de mutation guidée GM une fois sur chacune des M meilleures solutions. Un opérateur de réparation est appliqué sur chaque solution générée, si nécessaire, puis MST, l'opérateur de pruning, MST et l'opérateur de pruning sont appliqués sur chaque solution générée pour améliorer sa fitness. Ajouter toutes les M nouvelles solutions générées avec N $p - M$ meilleures solutions à $\text{pop}(g)$ pour former $\text{pop}(g+1)$. Si le critère d'arrêt est satisfait, retourner l'arbre dominant avec le poids minimum trouvé jusqu'à présent

$g \leftarrow g + 1$

si *la meilleure solution de la population ne s'améliore pas après S générations*

alors

 réinitialiser toute $\text{pop}(g)$, sauf la meilleure solution, puis initialiser le vecteur de probabilités p pour tous les nœuds en utilisant l'Algorithme 18

fin

fin

3.8 Conclusion

Dans ce chapitre nous avons présenté le problème de l'arbre dominant, qui est une des approches utilisées pour la résolution du problème de consommation de l'énergie dans les réseaux de capteurs sans fil. Comme la construction de DT est NP-hard, Shin et Thai ont proposé une approximation de ce dernier en DST pour optimiser le temps de construction de l'arbre dominant [5], et d'autres chercheurs ont opté pour le développement des méta-heuristiques pour la même raison. Cependant, on ne peut pas tout avoir dans une méta-heuristique (c'est à dire qu'une méta-heuristique peut donner des meilleurs résultats en terme temps de calcul et d'autre en terme de qualité de solution) pourquoi ne pas penser à combiner des méta-heuristiques pour des résultats plus fiables ?.

CHAPITRE 4

APPROCHE PROPOSÉE

4.1 Introduction

Dans les chapitres précédents, nous avons introduit différentes techniques utilisées pour la résolution des problèmes d'optimisation combinatoire, notamment les méthodes adoptées pour la résolution du problème de l'arbre dominant DTP, dont une grande majorité a servi de source d'inspiration pour l'élaboration des approches que nous avons proposé et qui seront détaillées le long de ce chapitre. Nous allons dans un premier présenter les structures de données utilisées pour représenter les données du problème ainsi que la solution.

4.2 Représentation du graphe modélisant le problème

Un WSN est un graphe pondéré non orienté $G = (V, E, w)$, où V est l'ensemble des nœuds du réseau, E l'ensemble des arêtes et w un poids non négatif attribué pour chaque arête $e = (u, v)$.

Nous utilisons pour représenter le WSN deux vecteurs, un vecteur de taille $|V|$ contenant des entiers représentant chaque nœud et l'autre est de taille $|V - 1|$ il contient une structure d'arc (nœud 1, nœud 2 et le poids entre les deux nœuds). Nous allons dans ce qui suit présenter le codage de la solution ainsi que la méthode d'extraction du DT à partir de cette solution.

4.3 présentation d'une solution

Nous proposons de représenter une solution en utilisant le codage binaire qui est considéré dans la littérature comme un bon moyen pour manipuler les différents gène (position(bit) dans une solution) d'une solution pour une population donnée. Si le gène est égale à '1', cela veut dire que le nœud correspondant est actif, s'il vaut '0', il est inactif.

4.4 Méthode d'extraction d'un arbre dominant à partir du vecteur solution

Au départ nous avons deux vecteurs $(Vect, DN)$, où, $Vect$ contient tous les nœuds de notre graphe, DN est un vecteur binaire de taille $|V|$ initialement null et contiendra par la suite l'ensemble des nœuds dominant .

L'ajout des nœuds à DN se fait via un processus itératif. A chaque fois un nœud est choisi d'une façon aléatoire, et est ajouté à DN . Ce processus poursuit son fonctionnement tant que les nœuds appartenant à DN ne couvrent pas tout le graphe ou ils ne sont pas connectés. On dit que DN couvre le graphe si et seulement si tous les nœuds de notre graphe sont soit dans DN soit adjacent à un autre nœud qui est dans DN .

Pour pouvoir construire un DT, il faut d'abord vérifier que les nœuds actifs dans DN sont connectés entre eux. Dans le meilleur des cas, les nœuds actifs dans DN sont connectés. Dans le cas contraire nous devons les rendre connectés en utilisant une méthode de connection décrite ci après.

4.5 La méthode de connection

Soit un vecteur DNC initialement vide qui va contenir par la suite ensemble de nœuds connectés. En premier lieu, nous retirons un nœud aléatoirement de DN et nous l'insérons dans DNC. Puis, d'une façon itérative, nous retirons tous les nœuds de DN qui ont au moins un voisin dans DNC et nous l'insérons dans DNC. En second lieu nous, devons insérer tous les nœuds actifs dans DN dans DNC en utilisant une autre fonction. Cette fonction consiste au départ, à choisir un nœud v aléatoirement dans V qui n'est pas dans DNC. S'il y a au moins deux voisins, un dans DN et l'autre dans DNC, alors nous retirons son voisin dans DN et nous l'insérons avec v dans DNC. Si aucun nœud n'est trouvé nous procédons à une sélection par paires de nœuds où chaque nœud entre eux a soit un voisin dans DN ou dans DNC et nous refaisons le même processus de recherche dans le cas d'un seul nœud à sélectionner.

Nous ré-exécutons ce processus jusqu'à ce que DN devienne null.

Une fois que l'ensemble DN soit null, nous appliquons la méthode d'élagage et MST décrits dans le chapitre 3. Nous aurons au final, un arbre dominant DT, représenté sous forme d'un vecteur de type arc (chaque élément de ce vecteur est composé d'un noeud1, noeud2, et le poids entre ces deux nœuds).

4.6 Approche proposée

Dans ce mémoire nous avons proposé plusieurs approches pour résoudre le DTP. Nous avons proposé de le résoudre dans un premier temps en utilisant des

méta-heuristiques, et en utilisant la coopération de ces méta-heuristiques dans un second temps. Nous allons structurer ce qui suit en deux parties. Dans la première partie, nous présentons chacune des méta-heuristiques utilisées, dans la seconde partie, nous présentons l'approche coopérative.

4.6.1 description des méta-heuristiques utilisées

La méthode de résolution du problème de l'arbre dominant que nous avons proposée consiste à intégrer un processus de recherche locale à la méta-heuristiques. Nous allons dans ce qui suit décrire les approches proposées.

4.6.1.1 Ant colony optimisation

Nous utilisons dans cette première solution, l'algorithme des colonies de Fourmies pour résoudre le DTP. Nous allons décrire dans ce qui suit l'adaptation des opérateurs de cette métaheuristique au problème étudié.

1. Les opérateurs de l'algorithme ACO

a) Recherche locale

Dans la recherche locale que nous proposons, supposons que nous avons une solution. Nous parcourons le vecteur de la solution et on inverse la valeur des élément (si la valeur d'un élément est égale à 1, elle devient 0 ou inversement). A chaque fois que nous inversons la valeur de chaque élément nous faisons une évaluation de la fonction objectif. A tous coups où la solution est améliorée, cette dernière est sauvegardée et la recherche d'une meilleure solution se fera à partir de cette solution.

La recherche se terminera lorsque tous les nœuds dominants auront été parcourus. il est à noter que la méthode de recherche locale citée ci dessus est utilisée dans toutes les solutions proposées.

b) Les méthodes de sélection

Nous proposons d'utiliser deux méthodes de sélection d'individus. Ces deux méthodes ont été retenues après une série d'expérimentations faisant apparaître les deux méthodes donnant les meilleurs résultats.

- **Méthode de sélection par Intensification** : son principe consiste à choisir le nœud ayant la plus grande probabilité pour améliorer la solution
- **La sélection par tournoi** : le principe de cette sélection consiste à choisir deux nœuds aléatoirement, puis de retenir celui ayant la meilleure probabilité

2. Fonctionnement de l'algorithme ACO

L'algorithme de colonie de fourmi est une approche métaheuristique basée sur une population et inspirée du comportement des fourmis réelles. L'idée principale derrière cette méthode provient de l'observation de la capacité des fourmis pour trouver le plus court chemin entre une source de nourriture et le nid. Cette méta-heuristique est composée d'une phase d'initialisation et d'une phase itérative. La première phase consiste à initialiser une solution de départ qui sera décrite ci-dessous. Elle comprend également l'initialisation du vecteur des probabilités et de la table de phéromone.

Ensuite, pour chaque itération, chaque fourmi construit sa solution en choisissant aléatoirement une méthode de sélection (intensification - sélection par tournois). Après avoir construit une solution la recherche locale est lancée pour atteindre un résultat meilleure. La meilleure solution retournée par la fourmi courante va participer à la mise à jour du vecteur de probabilité(mise à jour en ligne) en appliquant la formule (1). A la fin de chaque itération, la meilleure solution trouvée par la population de fourmis va elle aussi participer à la mise à jour du vecteur de probabilité (mise à jour hors ligne) avec la formule suivante :

$$p_{ij}^k = \frac{[T_j]^\alpha [n_{ij}]^\beta}{\sum_{h \in S} \sum_{l \in N_h^k} [T_l]^\alpha [n_{hl}]^\beta} \quad (1)$$

où :

T_j la concentration de phéromone du nœud j

n_{ij} est le terme heuristique qui vaut $1/w_{ij}$, dont w_{ij} est le poids de l'arc du nœud i vers le nœud j .

α, β sont deux paramètres qui déterminent l'influence relative de la trace de phéromone et de l'information heuristique dans le processus de génération des solutions.

N_h^k est l'ensemble de sommets non sélectionnés adjacents à un sommet

$h \in S$.

Nous allons décrire dans ce qui suit, l'approche de construction de la solution initiale. Soit S l'ensemble des solutions (initialement vide). Tous les sommets de notre graphe sont étiquetés initialement comme non marqués. Un sommet v est sélectionné aléatoirement dans l'ensemble V puis ajouté à S . Ce sommet est étiqueté comme marqué et tous les sommets adjacents à ce sommet deviennent marqués. Après cela, à chaque étape, la fourmi k construit une solution en sélectionnant un sommet non sélectionné v adjacent à un sommet déjà sélectionné $u \in S$. La sélection de ce sommet non sélectionné v est déterminée de manière probabiliste.

Après que tous les sommets du graphe soient étiquetés à marqué. Les fonction élagage et MST décrit dans le chapitre 3 sont appliquées.

Le pseudo-code de ACO est donné dans l'algorithme 1 suivant :

Algorithme 23 : ACO DT

Données : Un graphe général pondéré non orienté $G = (V, E, w)$

Résultat : Un DT optimal de G

Initialiser le vecteur de probabilité ainsi que la table de pheromone

Construction de la solution initiale

tant que le nombre d'itération non atteint **faire**

pour chaque fourmi **faire**

 Construction d'une solution

 Recherche locale()

 Mise à jour de la table de phéromone. Selon la meilleure solution trouvée par la fourmi

fin

 Mise à jour de la table de phéromone Selon la meilleur solution atteinte par les fourmis

fin

Retourner le DT avec poids minimum dans la liste

4.6.1.2 Algorithme génétique

Nous allons décrire dans ce qui suit les opérateurs retenus dans l'approche utilisant les algorithmes génétiques.

1. Les opérateurs de l'algorithme ACO

a) **Génération de la Population initiale**

La population initiale est construite avec un ensemble de solutions (individu) définies aléatoirement. La taille de chaque individu est le même nombre de nœuds dans un réseaux de capteurs sans fil.

b) **Codage des éléments d'une population**

Le codage utilisé dans cette approche est celui décrit dans la section II.

c) **La méthode de croisement utilisée :**

Pour cet algorithme nous avons utilisé la méthode de croisement uniforme. Il opère à l'aide d'un masque construit aléatoirement, pour décider lequel des parents va transmettre la valeur du gène à l'un ou l'autre des descendants. Si à la même position que le gène, la valeur du masque est égale à 1, le gène du parent 1 passe à celui de l'enfant 1 et le gène du parent 2 passe à l'enfant 2. Sinon, c'est l'inverse qui se produit (figure 4.1). Cette fonction renvoie l'enfant ayant la meilleur qualité (le poids minimal).

La figure 4.1 illustre se processus par un exemple.

Parent 1	1	0	0	0	1	1	1	1	1	0
Parent 2	1	1	1	1	0	0	0	0	0	1
Masque	1	0	0	1	1	1	0	0	1	0
Enfant 1	1	1	1	0	1	1	0	0	1	1
Enfant 2	1	0	0	1	0	0	1	1	0	0

Fig. 4.1 – Exemple de croisement uniforme

d) **Mutation**

La mutation est une autre solution pour créer de nouveaux individus et de modifier ceux déjà existant. Le hasard dans cette méthode va nous être d'une grande utilité. Dans notre cas, un index généré aléatoirement va décider dans quelle position le gène à muter se trouve. Rien ne nous dit que l'individu muté sera meilleure ou au moins bon, mais il pourrait être efficace pour la création de bonnes solutions. Un exemple illustratif sera représenté par la figure 4.2.

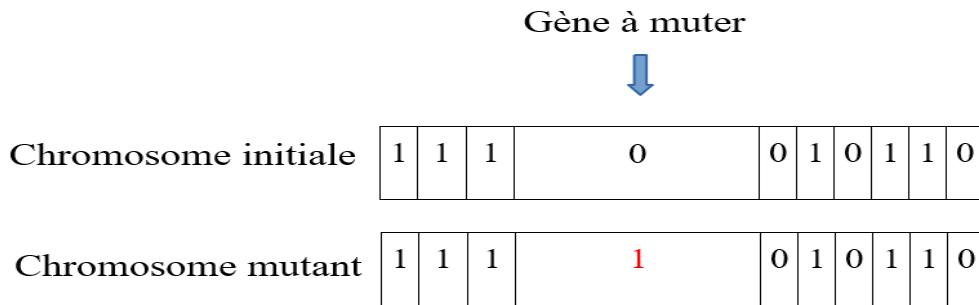


Fig. 4.2 – Représentation schématique de la mutation

e) Élitisme

Cet opérateurs permet de garder les meilleurs individus de chaque population. Notre méthode d'élitisme consiste à remplacer les m mauvais individus de la nouvelle population par les m meilleurs individus de la population précédente.

2. Fonctionnement de l'algorithme génétique (GA)

Après avoir créé une population initiale, l'algorithme GA procède comme suit :

Algorithme 24 : Génétique DT

```

Initialiser une population d'une façon aléatoire
tant que  $i < \text{Nombre d'itération}$  faire
    tant que  $j < \text{PopSize}$  faire
        Récupérer deux individu de la population  $n_1, n_2$ 
         $\text{Enfant} = \text{Croisement}(n_1, n_2)$ 
         $\text{rand} = \text{Rand}(0, 100)$ 
        si  $\text{rand} < 5\%$  alors
            Mutation(Enfant)
        fin
        Recherche locale()
        Ajouter le meilleur individu à la nouvelle population
    fin
    Elitisme()
fin

```

4.6.1.3 biogeography based optimisation (BBO)

C'est une méta heuristique qui fait partie des algorithmes évolutionnaire basée sur la biogéographie. Dans ce qui suit, nous allons présenter l'approche BBO développée pour la résolution du problème de l'arbre dominant ainsi que

ses opérateurs.

1. Les opérateurs de l'algorithme BBO

Il est à noter que le codage d'une solution et l'initialisation de la population sont les mêmes que celles décrites pour l'algorithme génétique. BBO utilise principalement deux opérateurs : la migration et la mutation

a) Migration

Le concept générale de cet opérateur est de décider laquelle des régions de la solution migre ou non vers une autre région. La migration d'une région est le fait qu'un élément d'une solution s'interchange avec un autre élément d'une autre solution. Il est généralement utilisé pour modifier l'individu existant. L'algorithme 3 décrit le fonctionnement de l'opérateur de migration utilisé par BBO .

Algorithme 25 : Migration BBO DT

Données : position d'un individu donnée j

tant que $i < \text{taille de population}$ **faire**

$rand = \text{Random}(0, 1)$

si $rand < \mu(I_i)$ **alors**

 choisir un sommet de l'individu dans la position j aléatoirement et le permuter
 avec un autre sommet de l'individu dans la position i

fin

fin

Où :

$\mu(I_i)$ Probabilité Emigration de l'individu I_i

b) Mutation

La mutation est un opérateur probabiliste. Le but de cet opérateur est de maintenir la diversité d'une population.

Algorithme 26 : Mutation BBO DT

Données : position d'un individu j, PM

tant que $i < \text{taille de l'individu}$ **faire**

$rand = \text{Random}(0, 1)$

si $rand < M_i$ **alors**

 permuter le nœud courant avec n'importe quel nœud défini dans une position
 aléatoire

fin

fin

Où :

M_i est la probabilité de mutation.

$$M_i = Pmut * (((1 - Pmut(j)))) / PmutMax$$

dont : $Pmut$ est une constante qui définit la probabilité de mutation.

$Pmut(j)$ est la probabilité de mutation de l'individu j .

$PmutMax$ est la probabilité de mutation maximale des individus de la population.

c) Mise à jours des probabilité

Les taux d'immigration (λ) et d'émigration (μ) de chaque individu I sont utilisés pour transmettre, de manière probabiliste, les caractéristiques entre les individus. Le taux d'immigration, quand il y a S individus dans la population, est donné par la formule (2) décrite ci-dessous :

$$\lambda(I_i) = 1 - \frac{nbv}{S} \quad (2)$$

Où :

nbv est le nombre d'individus qui ont une valeur de la fonction objectif pire que l'individu courant (I_i).

Le taux d'émigration quand il y a S individus dans la population est donné par :

$$\mu(I_i) = \frac{nbv}{S} \quad (3)$$

Quant aux taux de la mutation est calculé en utilisant les résultats des deux formules précédentes et est donné par :

$$Pmut(I_i) = \frac{\lambda_i / \mu_i}{\sum_{j=0}^{j=S} \lambda_j / \sum_{j=0}^{j=S} \mu_j} \quad (4)$$

2. Le fonctionnement de l'algorithme BBO

L'algorithme BBO que nous avons développé peut être décrit globalement par l'algorithme 27. Les deux opérateurs de base qui régissent le fonctionnement de BBO sont la migration et la mutation et sont les mêmes décrites ci-dessus. En plus, une stratégie d'élitisme est adoptée dans l'algorithme

BBO, afin de garder dans la nouvelle population la meilleure solution.

Algorithme 27 : Algorithme BBO DT

```
Initialisation de la population
tant que la condition d'arrêt non vérifiée faire
    Mise à jours des probabilité (Emigration, Immigration, Mutation)
    pour chaque Individu  $I_i$  de la population faire
         $rand = Rand(0, 1)$ 
        si  $rand < \lambda(I_i)$  alors
            Migration()
        sinon
            Mutation()
        fin
        Recherche Local()
    fin
    Elitisme ()
fin
```

4.6.2 Description de l'approche coopérative

Nous proposons une approche coopérative entre les méta-heuristiques pour la résolution du problème de l'arbre dominant où une méta-heuristique maître contrôle plusieurs méta-heuristiques esclaves. Les points forts d'une méta-heuristique esclave compensent les points faibles d'une autre grâce à la notion de rang. Le rang est un moyen de mettre en valeur les points forts des méta-heuristiques esclaves. Il est attribué par le maître et est égale à 0 au départ. Il est mis à jour continûment par la méta-heuristique maître qui augmente le rang des méta-heuristiques esclaves ayant amélioré la solution et diminue le rang de celles qui ne l'auront pas amélioré. Cette mise à jour tend à récompenser les méta-heuristiques esclaves qui auront réussi à améliorer la solution courante. Comme conséquence, les méta-heuristiques esclaves ayant un rang élevé participeront donc davantage au développement de la solution finale.




Fig. 4.3 – Coopération des méta-heuristiques

Comme le montre la figure 4.3, nous utilisons comme méta-heuristique maître la recherche taboue, et pour les méta-heuristiques esclaves nous utilisons l'algorithme génétique, ACO ainsi que BBO. Au départ, le maître choisit une méta-heuristique esclave de manière aléatoire. A chaque fois qu'une méta-heuristique esclave améliore sa solution, elle aura comme bonus une valeur supérieure de rang, cela crée une forme de compétition entre les esclaves pour accroître son rang tout en améliorant la solution actuelle.

Lorsqu'une méta-heuristique termine sa recherche, elle communique sa meilleure solution à celle qui la remplace, permettant ainsi à cette dernière de générer un bon voisinage. La sélection de la méta-heuristique remplaçante se fait par rapport à la valeur du rang (c'est-à-dire la méta-heuristique ayant le plus grand rang sera choisie pour l'amélioration de la solution courante). La méta-heuristique esclaves n'ayant pas amélioré la solution après un nombre d'itération précis elle sera mis dans la liste taboue. Lorsque toutes les méta-heuristiques sont dans la listes tabou la méta-heuristique maître libère l'esclave ayant un rand élevé pour contribuer à la recherche d'une meilleure solution. L'algorithme 28 présente le processus de fonctionnement de la méta-heuristique maître :

Algorithme 28 : Algorithme de la méta-heuristique maître

```

tant que condition d'arrêt non vérifiée faire
  Choisir la méta-heuristique ayant uen rand élevé et qui n'est pas dans la liste taboue
  si la méta-heuristique choisi donne une meilleure fitness alors
    rand = rand +  $\alpha$ 
    Vider la liste taboue
  sinon
    rand = rand +  $\alpha$ 
    Mettre la méta-heuristique esclave courante dans la liste taboue
  fin
fin
  
```

Où :

α représente : une valeur positive, si la qualité de la solution est améliorée, sinon α sera négatif.

L'algorithme suivant va définir le processus générale de la méthode de coopération.

Algorithme 29 : Algorithme de coopération

```

tant que condition d'arrêt non vérifiée faire
    si la list taboue est pleine alors
        récupérer la méta-heuristique ayant un rand élevé
    sinon
        choisir la méta-heuristique ayant un rand élevé et qui n'est pas dans la liste
        taboue
    fin
    executer la méta choisie et récupérer la solution trouvé S
    si S est meilleure que la meilleure solution trouvée SB alors
        SB = S
        Vider la liste taboue
    sinon
        mettre la méta dans la lise taboue
    fin
    mise à jour du rand
fin

```

4.7 Conclusion

A travers ce chapitre, nous avons présenté de manière détaillée les méta-heuristiques que nous avons proposé pour la résolution du problème de l'arbre dominant, ainsi que les différentes méthodes et opérateurs contribuant à leurs élaborations. Nous avons aussi proposé une nouvelle approche qui consiste à faire coopérer plusieurs méta-heuristique (esclaves) pour travailler dans l'espace des solutions supervisés par la méta-heuristique maître qui travaille dans l'espace des méta-heuristiques. Dans le but d'évaluer la qualité de ces approches, le prochain chapitre portera sur les différents résultats obtenus à travers les expérimentations effectuées.

CHAPITRE 5

ÉTUDE EXPÉRIMENTALE

5.1 Introduction

Dans le chapitre précédent, nous avons présenté en détail les approches que nous avons proposées pour la résolution du problème de l'arbre dominant (DTP). Nous allons présenter dans ce qui suit une étude expérimentale effectuée pour comparer les résultats des approches proposées avec d'autres approches développées pour la résolution du DTP. Nous clôturons avec une conclusion.

5.2 Environnement de travail

5.2.1 Environnement matériel

Pour les tests effectués nous avons utilisé une machine. Les caractéristiques de machine sont données dans la figure 5.1.

Informations système générales

Édition Windows

Windows 10 Professionnel

© 2018 Microsoft Corporation. Tous droits réservés.



Système

Processeur : Intel(R) Core(TM) i3-3110M CPU @ 2.40GHz 2.40 GHz

Mémoire installée (RAM) : 4,00 Go

Type du système : Système d'exploitation 64 bits, processeur x64

Fig. 5.1 – Caractéristiques de la machine utilisée

5.2.2 Environnement logiciel

Nous avons opté pour le langage Java pour la programmation, car il offre une grande flexibilité et facilite l'implémentation qui est due au fait qu'il soit totalement orienté-objet.

IDE : L'environnement de développement choisit est IntelliJ IDEA, spécialement dédié au développement en utilisant le langage Java. Il est proposé par

l'entreprise JetBrains et est caractérisé par sa forte simplicité d'utilisation et les nombreux plugins et extensions qui lui sont dédiées.

5.3 Jeux de données utilisées

Afin de tester l'approche proposée, nous avons opté pour l'utilisation de fichiers benchmark qui vont représenter des instances du problème. Les différentes instances sur lesquelles notre étude s'est portée sont dérivées à partir des mêmes benchmarks de [45]. Une instance est considérée comme un graphe de disques, $G = (V, E)$ où chaque disque représente la plage de transmission de chaque nœud. Le poids de chaque arête $e_{uv} \in E$ est défini sous la forme $w(u, v) = d_{uv}^2$, où d_{uv} est la distance euclidienne entre deux nœuds u et v . L'hypothèse est que tous les nœuds sont répartis de manière aléatoire dans une zone de $500m * 500m$ et la plage de transmission de chaque nœud est de 100 m.

5.4 Expérimentation

Pour montrer l'efficacité de l'approches proposées nous ne nous sommes pas limité à des instances de problème ayant un certain nombre de nœuds.

Nous nous avons effectué cela pour une large plage de nombre de nœuds (50 - 500).

Pour ACO, nous avons utilisé une population de 15 fourmis. Nous avons utilisé $\alpha = 1$, $\beta = 1$, $p = 0.05$, $P_0 = 0.1$. Toutes les valeurs de phéromone initiales sont égales à 0,05. Pour BBO et GA, la taille de la population est de 20 individus. Quant à l'approche de coopération, nous avons utilisé 0.5 comme probabilité initiale et 0,1 pour la valeur de α .

Pour toutes les instances du test, nous avons opté pour 100 itérations pour chacune des approches proposées. Nous avons jugé que ce nombre d'itérations est suffisant pour une qualité quasi optimale de la solution. Donner plus d'itérations à nos approches que celles mentionnées ci-dessus n'aura que peu d'impact sur la qualité de la solution.

Toutes ces valeurs de paramètres sont choisies empiriquement. Ces valeurs de paramètres donnent de bons résultats pour la majorité des instances de test.

5.4.1 Étude comparative

Afin de mener à bien une étude comparative entre nos approches et d'autres travaux effectués pour la résolution du DTP, nous avons gardé approximativement le même nombre d'évaluations de la fonction objectif.

Dans le but d'assurer l'intégrité des résultats, nous avons effectué un total de 20 exécutions pour chacune des instances. Les résultats d'exécutions de nos approches (ACO, BBO, GA et la méthode coopérative) sur les instances citées auparavant, sont illustrés dans le Tableau 5.1.

Dans le Tableau 5.1, les lignes correspondent aux différentes instances étudiées, quant aux colonnes, elles représentent, pour chaque approche : la meilleure solution obtenue (colonne BS), la moyenne de toutes les solutions obtenues sur les 20 exécutions (colonne AVG), le nombre d'évaluations nécessaire pour trouver la meilleure solution (colonne NBV) et la colonne qui représente le temps d'exécution de chaque métaheuristique en seconde (colonne sec). Notez que les meilleures valeurs sont indiquées en gras dans les tableaux comparatifs.

Instances	ACO				BBO				GA				Coopération			
	BS	NBV	Sec	AVG	BS	NBV	Sec	AVG	BS	NBV	Sec	AVG	BS	NBV	Sec	AVG
50_1	1204,41	994	0,28	1204,41	1204,41	8799	2,37	1204,41	1204,41	994	0,28	1204,41	1204,41	643	10,61	1204,41
50_2	1340,44	946	0,21	1340,44	1340,44	3858	1,59	1340,44	1340,44	946	0,21	1340,44	1340,44	3109	7,70	1340,44
50_3	1316,39	902	0,17	1316,39	1316,39	3265	1,43	1316,39	1316,39	902	0,17	1316,39	1316,39	4014	5,19	1316,39
100_1	1217,47	20238	7,32	1217,47	1217,47	27326	4,56	1217,47	1217,47	20238	7,32	1217,47	1217,47	9645	9,55	1217,47
100_2	1128,40	8631	2,65	1128,40	1128,40	18807	4,02	1128,40	1128,40	8631	2,65	1128,40	1128,40	21078	16,12	1128,40
100_3	1252,99	88122	24,19	1255,89	1252,99	485097	58,77	1253,89	1252,99	88122	24,19	1255,89	1252,99	127915	15,26	1254,15
200_1	1206,79	77846	52,44	1217,46	1206,79	207530	64,53	1210,46	1206,79	77846	52,44	1217,46	1206,79	196350	107,37	1206,79
200_2	1216,23	49921	38,66	1230,39	1214,85	1106206	355,15	1225,39	1216,23	49921	38,66	1230,39	1214,85	856467	632,90	1216,16
200_3	1247,62	62483	41,57	1270,13	1247,25	409505	115,54	1252,13	1247,62	62483	41,57	1270,13	1247,25	281973	271,80	1249,13
300_1	1215,48	171236	296,36	1232,90	1215,48	559687	304,15	1222,90	1215,48	171236	296,36	1232,90	1215,48	416987	515,97	1220,76
300_2	1172,87	127417	123,83	1185,69	1170,85	205275	116,56	1176,04	1172,87	127417	123,83	1185,69	1170,85	350850	143,58	1174,65
300_3	1261,64	508725	464,99	1289,37	1249,54	629728	267,17	1260,51	1261,64	508725	464,99	1289,37	1247,51	419826	382,91	1252,74
400_1	1220,97	65436	82,71	1229,24	1211,39	560534	539,46	1216,92	1220,97	65436	82,71	1229,24	1211,39	763589	471,99	1215,43
400_2	1209,90	557776	1174,42	1216,48	1201,16	691873	569,46	1206,96	1209,90	557776	1174,42	1216,48	1199,92	1763961	1195,46	1203,27
400_3	1261,35	1399470	2104,36	1276,25	1249,60	2880204	1980,41	1269,25	1261,35	1399470	2104,36	1276,25	1249,94	1794532	1361,79	1256,18
500_1	1205,59	630376	1488,63	1224,73	1198,27	1815043	1539,46	1216,92	1205,59	630376	1488,63	1224,73	1198,27	1101364	947,81	1209,46
500_2	1248,82	978224	2167,17	1253,10	1220,47	2459096	1622,79	1240,39	1248,82	978224	2167,17	1253,10	1220,47	1946589	1365,48	1231,28
500_3	1251,03	628099	1010,09	1274,11	1231,81	1508479	1028,26	1249,88	1251,03	628099	1010,09	1274,11	1231,81	1468317	994,41	1246,74

Tableau 5.1 – Résultats d'exécutions des approches proposées

5.4.1.1 Comparaison de la méthode coopérative avec les autres approches

Dans ce qui suit nous allons présenter une comparaison entre notre approche coopérative et les autres approches que nous avons développées. Cette comparaison a pour but de montrer l'efficacité de notre approche coopérative par rapport aux approches développées.

a) Avec l'approche ACO

D'après le graphe de la figure 5.2 et les résultats présentés dans le tableau 5.2, les résultats des deux approches sont similaires pour les 11 premières instances. La meilleure solution (BS) obtenue par l'approche coopérative est meilleure que celle obtenue par ACO pour les sept (7) dernières instances. Il faut également noter que la qualité moyenne des solutions (AVG) obtenue par la méthode de coopération est meilleure que celle d'ACO pour la majorité des instances du problème. Comparé à ACO, le nombre d'évaluation donnée par l'approche de coopération est relativement faible. Enfin, le temps d'exécutions d'ACO en général est moins important.

instances	ACO				Coopération			
	BS	NBV	Sec	AVG	BS	NBV	Sec	AVG
50_1	1204.41	994	0.2807628	1204.41	1204.41	643	10.605	1204.41
50_2	1340.44	946	0.209979	1340.44	1340.44	3109	7.6984	1340.44
50_3	1316.3898	902	0.1719828	1316.3898	1316.3898	4014	5.189	1316.3898
100_1	1217.47	20238	7.3182681731	1217.47	1217.47	9645	9.54674532	1217.47
100_2	1128.4	8631	2.65173482	1128.4	1128.4	21078	16.117388	1128.4
100_3	1252.99	88122	24.1905809	1255.89	1252.99	127915	15.26117	1254.15
200_1	1206.79	77846	52.442757	1217.46	1206.79	196350	107.3654	1206.79
200_2	1216.2301	49921	38.664135	1230.3901	1214.85	856467	632.898	1216.157
200_3	1247.62	62483	41.57384	1270.13	1247.2499	281973	271.799	1249.13
300_1	1215.4801	171236	296.36435	1232.8999	1215.4801	416987	515.9671	1220.763
300_2	1172.87	127417	123.826614	1185.6905	1170.8501	350850	143.579	1174.65
300_3	1261.64	508725	464.9945	1289.3695	1247.51	419826	382.9146	1252.744
400_1	1220.9698	65436	82.707726	1229.235	1211.39	763589	471.989	1215.43
400_2	1209.9	557776	1174.4196	1216.478	1199.92	1763961	1195.463	1203.27
400_3	1261.35	1399470	2104.3577	1276.25	1249.94	1794532	1361.793	1256.18
500_1	1205.5898	630376	1488.6282	1224.731	1198.2699	1101364	947.8137	1209.46
500_2	1248.82	978224	2167.1724	1253.103	1220.4701	1946589	1365.4801	1231.28
500_3	1251.0298	628099	1010.092	1274.1149	1231.81	1468317	994.4106	1246.735

Tableau 5.2 – Résultats d'exécutions d'ACO et la méthode de coopération




Fig. 5.2 – Diagrammes d’executions de la méthode ACO et la méthode coopérative

b) Avec l’approche BBO

D’après le graphe de la figure 5.3 les deux approches sont similaires. De même, en analysant le tableau 5.3, la meilleure solution (BS) obtenue par la méthode BBO et celle obtenue par l’approche de coopération est pratiquement la même.

Concernant les moyennes des solutions (AVG), celles obtenues par l’approche coopérative sont de meilleures qualités par rapport à celles obtenues par BBO.

Pour ce qui est du nombre d’évaluations celui de l’approche coopérative est négligeable comparé à l’autre approche.

instances	BBO				Coopération			
	BS	NBV	Sec	AVG	BS	NBV	Sec	AVG
50_1	1204.41	8799	2.3717628	1204.41	1204.41	643	10.605	1204.41
50_2	1340.44	3858	1.5948405	1340.44	1340.44	3109	7.6984	1340.44
50_3	1316.3898	3265	1.4288571	1316.3898	1316.3898	4014	5.189	1316.3898
100_1	1217.47	27326	4.5565443	1217.47	1217.47	9645	9.54674532	1217.47
100_2	1128.4	18807	4.020598	1128.4	1128.4	21078	16.117388	1128.4
100_3	1252.99	485097	58.774124	1253.89	1252.99	127915	15.26117	1254.15
200_1	1206.79	207530	64.534546	1210.46	1206.79	196350	107.3654	1206.79
200_2	1214.85	1106206	355.1485	1225.3901	1214.85	856467	632.898	1216.157
200_3	1247.2499	409505	115.54244	1252.13	1247.2499	281973	271.799	1249.13
300_1	1215.4801	559687	304.15057	1222.8999	1215.4801	416987	515.9671	1220.763
300_2	1170.8501	205275	116.56335	1176.04	1170.8501	350850	143.579	1174.65
300_3	1249.54	629728	267.17328	1260.5099	1247.51	419826	382.9146	1252.744
400_1	1211.39	560534	539.45905	1216.92	1211.39	763589	471.989	1215.43
400_2	1201.1602	691873	569.45703	1206.96	1199.92	1763961	1195.463	1203.27
400_3	1249.6	2880204	1980.413	1269.25	1249.94	1794532	1361.793	1256.18
500_1	1198.2699	1815043	1539.45905	1216.92	1198.2699	1101364	947.8137	1209.46
500_2	1220.4701	2459096	1622.7858	1240.39	1220.4701	1946589	1365.4801	1231.28
500_3	1231.81	1508479	1028.2551	1249.8799	1231.81	1468317	994.4106	1246.735

Tableau 5.3 – Résultats d’executions de BBO et la méthode de coopération




Fig. 5.3 – Diagrammes d’executions de la méthode BBO et la méthode coopérative

c) Avec l’approche GA

D’après le graphe de la figure 5.4 et les résultats présentés dans le tableau 5.4, les deux approches sont similaires pour les 11 premières instances, la meilleure solution (BS) obtenue par l’approche coopérative est meilleure que celle obtenue par GA pour les sept (7) dernières instances. Il faut également noter que la qualité moyenne des solutions (AVG) obtenue par la méthode de coopération est de meilleure qualité que celle obtenue par GA pour toutes les instances du problème. Comparé à GA, le nombre d’éva-

luation donnée par l'approche de coopération est relativement faible.

instances	GA				Coopération			
	BS	NBV	Sec	AVG	BS	NBV	Sec	AVG
50_1	1204.41	994	0.2807628	1204.41	1204.41	643	10.605	1204.41
50_2	1340.44	946	0.209979	1340.44	1340.44	3109	7.6984	1340.44
50_3	1316.3898	902	0.1719828	1316.3898	1316.3898	4014	5.189	1316.3898
100_1	1217.47	20238	7.3182681731	1217.47	1217.47	9645	9.54674532	1217.47
100_2	1128.4	8631	2.65173482	1128.4	1128.4	21078	16.117388	1128.4
100_3	1252.99	88122	24.1905809	1255.89	1252.99	127915	15.26117	1254.15
200_1	1206.79	77846	52.442757	1217.46	1206.79	196350	107.3654	1206.79
200_2	1216.2301	49921	38.664135	1230.3901	1214.85	856467	632.898	1216.157
200_3	1247.62	62483	41.57384	1270.13	1247.2499	281973	271.799	1249.13
300_1	1215.4801	171236	296.36435	1232.8999	1215.4801	416987	515.9671	1220.763
300_2	1172.87	127417	123.826614	1185.6905	1170.8501	350850	143.579	1174.65
300_3	1261.64	508725	464.9945	1289.3695	1247.51	419826	382.9146	1252.744
400_1	1220.9698	65436	82.707726	1229.235	1211.39	763589	471.989	1215.43
400_2	1209.9	557776	1174.4196	1216.478	1199.92	1763961	1195.463	1203.27
400_3	1261.35	1399470	2104.3577	1276.25	1249.94	1794532	1361.793	1256.18
500_1	1205.5898	630376	1488.6282	1224.731	1198.2699	1101364	947.8137	1209.46
500_2	1248.82	978224	2167.1724	1253.103	1220.4701	1946589	1365.4801	1231.28
500_3	1251.0298	628099	1010.092	1274.1149	1231.81	1468317	994.4106	1246.735

Tableau 5.4 – Résultats d'exécutions de GA et la méthode de coopération




Fig. 5.4 – Diagrammes d'exécutions de la méthode GA et la méthode coopérative

5.4.1.2 Comparaison de la méthode coopérative avec les travaux liés au DTP

Afin de monter l'efficacité et la robustesse de notre approche coopérative, Nous l'avons comparé à deux techniques méta-heuristiques basées sur un essaim dans la littérature, à savoir ACO_DT [51] et ABC_DT [47], et une autre méta-heuristique SSGA [22] .

a) **Comparaison de la méthode coopérative avec ABC_DTP**

Dans le tableau V.5 notre méthode de coopération est meilleure sur 5 instances et similaire pour 11 instances sur 18 instances. En terme de solution moyenne, on remarque que la coopération est meilleure sur 8 instances, de moindre qualité pour 8 autres instances et est similaire pour 2 instances.

instances	ABC_DTP			Coopération		
	BS	AVG	Sec	BS	AVG	Sec
50_1	1204.41	1204.41	0.44	1204.41	1204.41	10.605
50_2	1340.44	1340.69	0.64	1340.44	1340.44	7.6984
50_3	1316.39	1316.39	0.56	1316.3898	1316.3898	5.189
100_1	1217.47	1218.59	1.11	1217.47	1217.47	9.54674532
100_2	1128.40	1136.50	1.12	1128.4	1128.4	16.117388
100_3	1252.99	1253.30	1.20	1252.99	1254.15	15.26117
200_1	1206.79	1210.25	4.31	1206.79	1206.79	107.3654
200_2	1216.41	1219.38	4.17	1214.85	1216.157	632.898
200_3	1247.73	1252.15	4.81	1247.2499	1249.13	271.799
300_1	1215.48	1220.39	11.50	1215.4801	1220.763	515.9671
300_2	1170.85	1171.15	9.73	1170.8501	1174.65	143.579
300_3	1249.54	1254.67	11.39	1247.51	1252.744	382.9146
400_1	1212.51	1214.36	27.15	1211.39	1215.43	471.989
400_2	1199.23	1202.90	25.44	1199.92	1203.27	1195.463
400_3	1246.94	1258.76	24.52	1249.94	1256.18	1361.793
500_1	1200.06	1208.73	54.61	1198.2699	1209.46	947.8137
500_2	1220.68	1230.07	54.86	1220.4701	1231.28	1365.4801
500_3	1231.95	1236.33	37.90	1231.81	1246.735	994.4106

Tableau 5.5 – Résultats d'exécutions de ABC_DTP et la méthode de coopération

b) **Comparaison de la méthode coopérative avec ACO_DT**

D'après le tableau 5.6, il est bien clair que la méthode de coopération est la meilleure technique en terme de la meilleure solution ainsi que la qualité moyenne de la solution. La méthode de coopération a pu générer une BS de meilleure qualité que celui d'ACO_DT pour la plupart des instances (huit instances) et une solution de moindre qualité par rapport à celle d'ACO_DT. Pour le reste des instances les résultats sont similaires pour les deux techniques. Concernant les moyennes des solutions obtenues (AVG), la coopération donne de meilleurs résultats que ACO_DT dans 13 instances, et fournit une solution de moindre qualité dans une seule instance. Les résultats sont similaires pour le reste des instances (6 instances).

instances	ACO_DT			Coopération		
	BS	AVG	Sec	BS	AVG	Sec
50_1	1204.41	1204.41	2.91	1204.41	1204.41	10.605
50_2	1340.44	1340.44	3.00	1340.44	1340.44	7.6984
50_3	1316.39	1316.39	3.09	1316.3898	1316.3898	5.189
100_1	1217.47	1217.47	9.77	1217.47	1217.47	9.54674532
100_2	1128.40	1143.21	7.71	1128.4	1128.4	16.117388
100_3	1253.49	1254.75	8.82	1252.99	1254.15	15.26117
200_1	1206.79	1211.52	31.17	1206.79	1206.79	107.3654
200_2	1216.23	1216.65	29.28	1214.85	1216.157	632.898
200_3	1247.25	1252.39	35.28	1247.2499	1249.13	271.799
300_1	1223.67	1230.13	87.32	1215.4801	1220.763	515.9671
300_2	1170.85	1171.85	75.12	1170.8501	1174.65	143.579
300_3	1249.54	1260.85	79.97	1247.51	1252.744	382.9146
400_1	1211.33	1219.80	152.61	1211.39	1215.43	471.989
400_2	1201.16	1211.15	130.40	1199.92	1203.27	1195.463
400_3	1256.02	1268.50	123.92	1249.94	1256.18	1361.793
500_1	1200.06	1218.31	229.41	1198.2699	1209.46	947.8137
500_2	1238.81	1248.83	215.61	1220.4701	1231.28	1365.4801
500_3	1231.81	1257.42	197.99	1231.81	1246.735	994.4106

Tableau 5.6 – Résultats d'exécutions d'ACO_DT et la méthode de coopération

c) Comparaison de la méthode coopérative avec SSGA

Comme le tableau 5.7 le montre, parmi les quatre instances, la meilleure solution (BS) obtenue par la coopération est similaire à celle obtenue par SSGA dans 11 instances et est moins bonne que la BS trouvé par SSGA dans une seule instance (400_3).

Concernant les moyennes des solutions (AVG), celles obtenues par la coopération sont similaires à celles obtenues par SSGA dans deux instances (50_2 et 300_2) et sont de moindre qualité par rapport à SSGA dans une seule instance (100_3).

Instances	SSGA			Coopération		
	BS	AVG	Sec	BS	AVG	Sec
50_1	1204.41	1204.43	0.73	1204.41	1204.41	10.605
50_2	1340.44	1340.44	1.31	1340.44	1340.44	7.6984
50_3	1316.39	1317.10	0.73	1316.3898	1316.3898	5.189
100_1	1217.47	1217.98	1.74	1217.47	1217.47	9.54674532
100_2	1128.40	1128.79	1.56	1128.4	1128.4	16.117388
100_3	1252.99	1253.26	1.98	1252.99	1254.15	15.26117
200_1	1206.79	1207.28	4.41	1206.79	1206.79	107.3654
200_2	1216.23	1217.63	4.30	1214.85	1216.157	632.898
200_3	1247.25	1251.69	4.89	1247.2499	1249.13	271.799
300_1	1226.11	1230.06	8.91	1215.4801	1220.763	515.9671
300_2	1170.85	1173.57	7.65	1170.8501	1174.65	143.579
300_3	1247.51	1253.73	8.35	1247.51	1252.744	382.9146
400_1	1213.45	1224.87	13.93	1211.39	1215.43	471.989
400_2	1199.67	1205.69	13.04	1199.92	1203.27	1195.463
400_3	1248.29	1265.25	12.59	1249.94	1256.18	1361.793
500_1	1203.34	1215.34	18.12	1198.2699	1209.46	947.8137
500_2	1233.89	1247.42	22.84	1220.4701	1231.28	1365.4801
500_3	1231.92	1251.23	17.76	1231.81	1246.735	994.4106

Tableau 5.7 – Résultats d'exécutions de SSGA et la méthode de coopération

5.4.2 Analyse graphique

5.4.2.1 Étude comparative entre les différentes approches sur les meilleures solutions (BS)

La Figure 5.5 représente graphiquement les valeurs des différentes BS obtenues par les méta-heuristiques ACO_DT, BBO, GA et la méthode coopérative, pour les 18 instances. On constate que les courbes présentent la même allure pour les instances de complexité moyenne. De plus, pour les instances de 300_2 à 500_3, l'approche de coopération donne des résultats avec un coût inférieur à celui des autres approches. Chose qui prouve l'efficacité de la méthode coopérative.

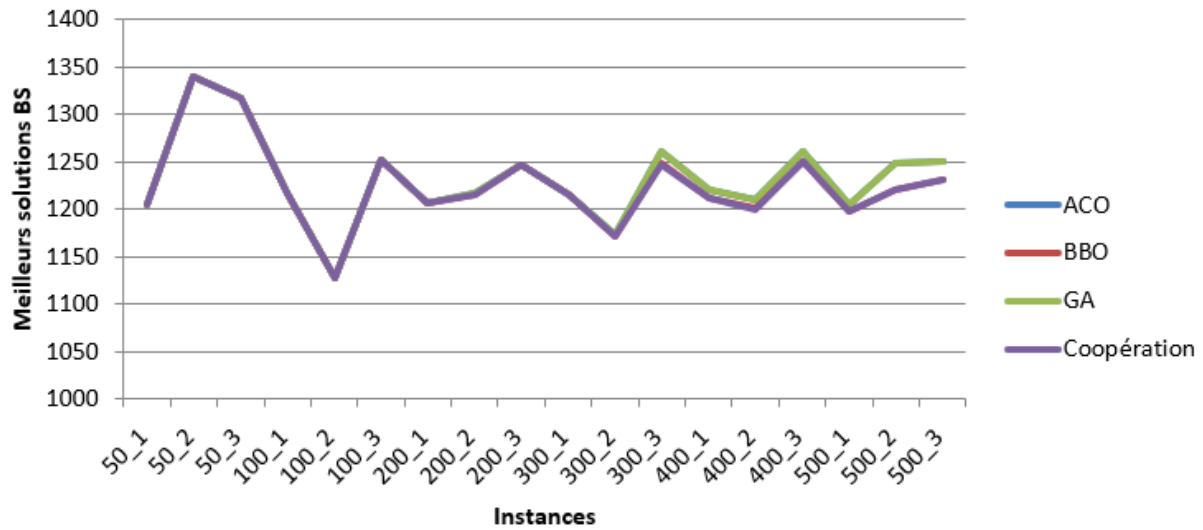


Fig. 5.5 – Diagrammes d'exécutions des approches proposées

5.4.2.2 Comparaison de la qualité moyenne des solutions (AVG) de l'approche coopérative et des autres approches

La Figure 5.6 porte sur la qualité moyenne des solutions (AVG) issues de 20 exécutions des différents algorithmes pour l'ensemble des 18 instances. On observe que les valeurs résultantes de l'approche coopérative avoisinent celles de ACO, BBO et GA et il est clairement aperçu que pour les grandes instances la coopération donne de bien meilleurs résultats que les autres approches. Ceci prouve que l'approche de coopération proposée s'adapte bien pour les grandes instances du problème.




Fig. 5.6 – Diagrammes de la Qualité moyenne de la solution AVG de des approches proposées

5.5 Conclusion

A travers ce dernier chapitre, nous avons étudié les résultats expérimentaux de l'approche proposée et les avons comparées selon quelques paramètres de performances (BS,AVG), avec d'autres travaux élaborés pour la résolution du problème de l'arbre dominant. Dans l'ensemble, les approches que nous avons proposées se sont avérées efficaces en offrant de bons résultats malgré la constatation de quelques dégradations de qualité qui peut se justifier par la nature stochastique des méta-heuristiques.

Conclusion général

Les travaux présentés dans ce projet de fin d'études traitent le fameux problème de l'arbre dominant qui est un des problèmes les plus traités dans le domaine de l'optimisation combinatoire.

Ce problème est apparu à l'époque où les Réseaux de Capteurs Sans Fils (RCSF) ont connu un grand développement ce qui leur a permis d'occuper une place très importante dans le monde de la recherche scientifique. En effet, il est né lors de l'apparition de la contrainte d'énergie qui représente un inconvénient majeur dans les RCSFs. Les plus grands taux de la consommation d'énergie ont lieu lors de la transmission des données.

Une des solutions consiste à fournir une ossature pour l'optimisation du routage des données permettant ainsi une économie d'énergie. Ceci revient à rechercher un arbre dominant de poids minimal.

L'objectif principal de notre projet de fin d'études est de proposer une méthode pour la résolution du problème de l'arbre dominant. Afin d'arriver à bout de notre solution, une étude des différentes techniques d'optimisation combinatoire a été nécessaire, ainsi qu'une étude approfondie des travaux élaborés dans le même but. Ce qui nous a permis d'adapter quelques méta-heuristiques inspirées de travaux antécédents.

Nous avons également mis en œuvre une nouvelle approche nommée l'approche coopérative, qui consiste à faire coopérer plusieurs méta-heuristiques esclaves soumises au contrôle d'une méta-heuristique maître. Malgré la difficulté du problème traité, ce fut véritablement une expérience fructueuse qui nous a ouvert les portes vers de nouveaux horizons. Pour conclure, nous avons réussi à mener notre projet à terme. L'application réalisée, nous a permis, comme prouvé dans les différents graphes d'atteindre des résultats très proches de ceux des travaux antérieurs et d'améliorer la majorité.

En guise de perspectives, nous envisageons d'intégrer un mécanisme d'adaptation des paramètres qui permettra de guider le comportement du processus de recherche en fonction d'indicateurs collectés au cours de l'exécution, ce qui ouvre par la suite une nouvelle fenêtre pour la recherche. Nous aimerions aussi, adapter l'approche proposée à d'autres problèmes similaires.

- [1] Vijay Raghunathan, Aman Kansal, Jason Hsu, Jonathan Friedman, and Mani Srivastava. Design considerations for solar energy harvesting wireless embedded systems. In *Proceedings of the 4th international symposium on Information processing in sensor networks*, page 64. IEEE Press, 2005.
- [2] Holger Karl and Andreas Willig. *Protocols and architectures for wireless sensor networks*. John Wiley & Sons, 2007.
- [3] Johann Dréo, Alain Pérowski, Patrick Siarry, and Eric Taillard. *Métaheuristiques pour l'optimisation difficile*. Eyrolles, 2003.
- [4] Jennifer Yick, Biswanath Mukherjee, and Dipak Ghosal. Wireless sensor network survey. *Computer networks*, 52(12) :2292–2330, 2008.
- [5] Incheol Shin, Yilin Shen, and My T Thai. On approximation of dominating tree in wireless sensor networks. *Optimization Letters*, 4(3) :393–403, 2010.
- [6] Ning Zhang, Incheol Shin, Bo Li, Cem Boyaci, Ravi Tiwari, and My T Thai. New approximation for minimum-weight routing backbone in wireless sensor network. In *International Conference on Wireless Algorithms, Systems, and Applications*, pages 96–108. Springer, 2008.
- [7] David H Wolpert, William G Macready, et al. No free lunch theorems for optimization. *IEEE transactions on evolutionary computation*, 1(1) : 67–82, 1997.

- [8] Mohamed Mekidiche and Hichem Rais. *Etude et évaluation du protocole de localisation DV-HOP dans un réseau de capteurs sans fil*. PhD thesis, <http://dspace.univ-tlemcen.dz/handle/112/7105>, 2015.
- [9] Jason Hill, Robert Szewczyk, Alec Woo, Seth Hollar, David Culler, and Kristofer Pister. System architecture directions for networked sensors. In *ACM SIGOPS operating systems review*, volume 34, pages 93–104. ACM, 2000.
- [10] Jessica Feng, Farinaz Koushanfar, and Miodrag Potkonjak. System-architectures for sensor networks issues, alternatives, and directions. In *null*, page 226. IEEE, 2002.
- [11] Paulo Rogério Pereira, António Grilo, Francisco Rocha, Mário Serafim Nunes, Augusto Casaca, Claude Chaudet, Peter Almström, and Mikael Johansson. End-to-end reliability in wireless sensor networks : Survey and research challenges. In *EuroFGI Workshop on IP QoS and Traffic Control*, volume 54, pages 67–74. Citeseer, 2007.
- [12] Anis Koubâa, Mário Alves, and Eduardo Tovar. Lower protocol layers for wireless sensor networks : a survey. 2005.
- [13] Abdelmalik Bachir, Mischa Dohler, Thomas Watteyne, and Kin K Leung. Mac essentials for wireless sensor networks. *IEEE Communications Surveys & Tutorials*, 12(2) :222–248, 2010.
- [14] GUNN Meghan and GM Simon. A comparative study of medium access control protocols for wireless sensor networks. *International Journal of Communications, Network and System Sciences*, 2(08) :695, 2009.
- [15] Ian F Akyildiz, Weilian Su, Yogesh Sankarasubramaniam, and Erdal Cayirci. Wireless sensor networks : a survey. *Computer networks*, 38(4) :393–422, 2002.
- [16] Ian F Akyildiz, Tommaso Melodia, and Kaushik R Chowdhury. A survey on wireless multimedia sensor networks. *Computer networks*, 51(4) :921–960, 2007.
- [17] Tim Nieberg, Stefan Dulman, Paul Havinga, Lodewijk van Hoesel, and Jian Wu. Collaborative algorithms for communication in wireless sensor networks. In *Ambient Intelligence : Impact on Embedded Sytem Design*, pages 271–294. Springer, 2003.

- [18] Sudipto Guha and Samir Khuller. Approximation algorithms for connected dominating sets. *Algorithmica*, 20(4) :374–387, 1998.
- [19] Myung Ah Park, James Willson, Chen Wang, My Thai, Weili Wu, and Andras Farago. A dominating and absorbent set in a wireless ad-hoc network with different transmission ranges. In *Proceedings of the 8th ACM international symposium on Mobile ad hoc networking and computing*, pages 22–31. ACM, 2007.
- [20] My T Thai, Ravi Tiwari, and Ding-Zhu Du. On construction of virtual backbone in wireless ad hoc networks with unidirectional links. *IEEE Transactions on Mobile Computing*, 7(9) :1098–1109, 2008.
- [21] Peng-Jun Wan, Khaled M Alzoubi, and Ophir Frieder. Distributed construction of connected dominating set in wireless ad hoc networks. In *Proceedings. Twenty-First Annual Joint Conference of the IEEE Computer and Communications Societies*, volume 3, pages 1597–1604. IEEE, 2002.
- [22] Shyam Sundar. A steady-state genetic algorithm for the dominating tree problem. In *Asia-Pacific Conference on Simulated Evolution and Learning*, pages 48–57. Springer, 2014.
- [23] Kamel Zidi. *Système interactif d’aide au déplacement multimodal (SIADM)*. PhD thesis, Ecole Centrale de Lille ; Université des Sciences et Technologie de Lille-Lille I, 2006.
- [24] Jin-Kao Hao, Philippe Galinier, and Michel Habib. Métaheuristiques pour l’optimisation combinatoire et l’affectation sous contraintes. *Revue d’intelligence artificielle*, 13(2) :283–324, 1999.
- [25] Jakob Puchinger and Günther R Raidl. Combining metaheuristics and exact algorithms in combinatorial optimization : A survey and classification. In *International Work-Conference on the Interplay Between Natural and Artificial Computation*, pages 41–53. Springer, 2005.
- [26] Alexander Schrijver. Theory of linear and integer programming. johnwiley & sons. *New York*, 1986.
- [27] Manfred Padberg and Giovanni Rinaldi. A branch-and-cut algorithm for the resolution of large-scale symmetric traveling salesman problems. *SIAM review*, 33(1) :60–100, 1991.

- [28] Manfred Padberg and Giovanni Rinaldi. Optimization of a 532-city symmetric traveling salesman problem by branch and cut. *Operations Research Letters*, 6(1) :1–7, 1987.
- [29] Mark Zlochin, Mauro Birattari, Nicolas Meuleau, and Marco Dorigo. Model-based search for combinatorial optimization : A critical survey. *Annals of Operations Research*, 131(1-4) :373–395, 2004.
- [30] Scott Kirkpatrick, C Daniel Gelatt, and Mario P Vecchi. Optimization by simulated annealing. *science*, 220(4598) :671–680, 1983.
- [31] Nicholas Metropolis, Arianna W Rosenbluth, Marshall N Rosenbluth, Augusta H Teller, and Edward Teller. Equation of state calculations by fast computing machines. *The journal of chemical physics*, 21(6) :1087–1092, 1953.
- [32] Ernesto Bonomi and Jean-Luc Lutton. The n-city travelling salesman problem : Statistical mechanics and the metropolis algorithm. *SIAM review*, 26(4) :551–568, 1984.
- [33] René VV Vidal. *Applied simulated annealing*, volume 396. Springer, 1993.
- [34] Fred Glover. Future paths for integer programming and links to artificial intelligence. *Computers & operations research*, 13(5) :533–549, 1986.
- [35] Roberto Battiti and Giampietro Tecchiolli. The reactive tabu search. *ORSA journal on computing*, 6(2) :126–140, 1994.
- [36] Alain Hertz and Daniel Kobler. A framework for the description of evolutionary algorithms. *European Journal of Operational Research*, 126(1) : 1–12, 2000.
- [37] JH Holland. Adaptation in natural and artificial systems : an introductory analysis. *Holland, JH*, 1975.
- [38] Ingo Rechenberg. Evolutionsstrategie : Optimierung technischer systeme nach prinzipien der biologischen evolution, frommann-holzboog. *Stuttgart, Germany*, 1973.
- [39] Lawrence J Fogel, Alvin J Owens, and Michael J Walsh. Artificial intelligence through simulated evolution. 1966.

- [40] John R Koza. Genetic programming : On the programming of computers by means of natural selection (complex adaptive systems). *A Bradford Book*, 1 :18, 1992.
- [41] Pablo Moscato et al. On evolution, search, optimization, genetic algorithms and martial arts : Towards memetic algorithms. *Caltech concurrent computation program, C3P Report*, 826 :1989, 1989.
- [42] My T Thai, Feng Wang, Dan Liu, Shiwei Zhu, and Ding-Zhu Du. Connected dominating sets in wireless networks with different transmission ranges. *IEEE transactions on mobile computing*, 6(7) :721–730, 2007.
- [43] Moses Charikar, Chandra Chekuri, To-yat Cheung, Zuo Dai, Ashish Goel, Sudipto Guha, and Ming Li. Approximation algorithms for directed steiner problems. *Journal of Algorithms*, 33(1) :73–91, 1999.
- [44] Robert Clay Prim. Shortest connection networks and some generalizations. *The Bell System Technical Journal*, 36(6) :1389–1401, 1957.
- [45] Shyam Sundar and Alok Singh. New heuristic approaches for the dominating tree problem. *Applied Soft Computing*, 13(12) :4695–4703, 2013.
- [46] Dervis Karaboga. An idea based on honey bee swarm for numerical optimization. Technical report, Technical report-tr06, Erciyes university, engineering faculty, computer . . . , 2005.
- [47] Dervis Karaboga and Bahriye Basturk. On the performance of artificial bee colony (abc) algorithm. *Applied soft computing*, 8(1) :687–697, 2008.
- [48] Lawrence Davis. Handbook of genetic algorithms. 1991.
- [49] Qingfu Zhang, Jianyong Sun, and Edward Tsang. An evolutionary algorithm with guided mutation for the maximum clique problem. *IEEE transactions on evolutionary computation*, 9(2) :192–200, 2005.
- [50] Sachchida Nand Chaurasia and Alok Singh. A hybrid heuristic for dominating tree problem. *Soft Computing*, 20(1) :377–397, 2016.
- [51] Shyam Sundar, Sachchida Nand Chaurasia, and Alok Singh. An ant colony optimization approach for the dominating tree problem. In *International Conference on Swarm, Evolutionary, and Memetic Computing*, pages 143–153. Springer, 2015.

Résumé